

Implementació Python d'algorismes d'estimació d'indicadors d'equilibri amb dades capturades per una IMU

Noa Janer Oliver

Resum– Aquest treball es centra en la implementació d'algoritmes d'estimació d'indicadors d'equilibri amb dades capturades per una Unitat de Mesura Inercial (IMU). L'objectiu principal és desenvolupar una alternativa econòmica i portàtil a la costosa plataforma de força, també anomenada posturograf. S'utilitzen xarxes neuronals de tipus RNN per predir l'Índex vestibular (VEST) en base a les dades capturades i el càlcul de les trajectòries. No obstant això, la petita quantitat de mostres del conjunt de dades i el desequilibri entre classes, fa que sigui molt difícil aconseguir resultats satisfactoris. Tot i les dificultats, s'espera que la recopilació continuada de dades porti a un conjunt de dades més extens i robust que possibilitarà una millora del rendiment dels algoritmes. Si s'assoleix un bon rendiment, aquesta aplicació pot tenir un impacte significatiu en l'avaluació de l'equilibri i la detecció precoç de malalties.

Paraules clau– Estimació, equilibri, IMU, RNN, índex vestibular, posturograf, trajectòria.

Abstract– This work focuses on the implementation of balance indicator estimation algorithms with data captured by an Inertial Measurement Unit (IMU). The main goal is to develop an inexpensive and portable alternative to the expensive force platform, also called a posturograph. RNN-type neural networks are used to predict the vestibular index (VEST) based on the captured data and the calculation of trajectories. However, the small amount of samples in the data set and unbalanced classes, makes it very difficult to achieve satisfactory results. Despite the difficulties, continued data collection is expected to lead to a more extensive and robust data set that will enable improved algorithm performance. If performed well, this application can have a significant impact on balance assessment and early disease detection.

Keywords– Estimation, balance, IMU, RNN, vestibular index, posturograph, trajectory.

1 INTRODUCCIÓ - CONTEXT DEL TREBALL

ACTUALMENT als Centres d'Atenció Primària es valora l'equilibri dels pacients mitjançant el **test de Romberg**, entre altres, amb una **plataforma de força**. Una plataforma de força és un instrument de mesura que mesura les forces de reacció del sòl generades per un cos que s'atura sobre elles o es mou sobre elles, per quantificar l'equilibri, la marxa i altres paràmetres de la biomecànica.[3] L'únic inconvenient d'aquest dispositiu és el seu elevat cost: de 300 a milers d'euros, i que és imprescindible realitzar la prova a un centre mèdic. Si aconseguíssim estimar els mateixos paràmetres amb una Unitat de Medi-

cio Inercial (IMU), els pacients podrien realitzar la prova als seus domicilis (el seu cost no arriba als cent euros [1]), i en cas que els estimadors sortissin positius, els pacients podrien acudir a un Centre d'Atenció Primària per fer una avaluació més detallada.

Així doncs l'objectiu d'aquest treball és aconseguir un algoritme per a estimar els indicadors d'equilibri SOM, VIS i VEST, explicats a l'apartat Conjunt de dades (3), a partir de dades recollides amb una IMU, en realitzar el Test de Romberg.

2 TEST DE ROMBERG

El **test de Romberg**, també conegut com a **prova de Romberg o maniobra de Romberg**, és una prova neurològica habitual que s'utilitza per diagnosticar trastorns que afecten l'equilibri i la coordinació motora (atàxia). Aquesta prova és freqüent als camps de la neurologia i l'otorrinolaringolo-

• E-mail de contacte: noajaneroliver@gmail.com
• Treball tutoritzat per: Marc Codina Barberà
• Curs 2022/23

gia.

El vertigen, el mareig i la dificultat per coordinar els moviments i mantenir l'equilibri són símptomes que poden indicar la presència de diferents patologies, com ara trastorns de l'aparell vestibular (p. ex., laberintitis, malaltia de Ménière, vertigen posicional paroxístic benigne) o patologies del sistema nerviós central (p. ex., migranyes, neuropaties, neoplàsies, accidents vascular cerebral o atàxies cerebel·loses).

La prova de Romberg consisteix a mantenir l'equilibri en posició dempeus amb els ulls tancats, amb l'objectiu de detectar trastorns relacionats amb l'aparell vestibular i el sistema nerviós central. Aquesta prova és útil per identificar alteracions en la posició del cos i la capacitat de mantenir l'equilibri, el que ajuda a detectar i diagnosticar trastorns de l'atàxia.

2.1 Com es fa la prova de Romberg?

La prova de Romberg és molt senzilla i no requereix preparació ni eines. Generalment es realitza durant una visita a un especialista neurològic i otorrinolaringològic o un examen vestibular. No obstant, si es realitza capturant dades amb una plataforma de forces, es pot proporcionar una mesura objectiva i quantitativa de l'equilibri i la postura del pacient.

Passos per realitzar la prova:

1. El pacient ha de mantenir-se dret amb les cames juntes durant 30 segons amb els ulls oberts. En aquest punt, s'extreu el **ROA** (fa referència a les sigles en castellà de *Romberg ojos abiertos*) respecte l'eix x i el ROA respecte l'eix y. És a dir, el desplaçament horitzontal i vertical.
2. Després, el pacient ha de mantenir la mateixa posició durant 30 segons més, aquesta vegada amb els ulls tancats. En aquest punt s'extreu el **ROC** (del castellà *Romberg ojos abiertos*) i el respectiu desplaçament horitzontal i vertical que s'ha produït en aquest pas. [5]

Ambdues proves es realitzen un total de 4 vegades, dues amb els peus al terra ferm, i dues més amb els peus sobre goma-escuma. En aquest últim cas la mesura capturada del desplaçament s'anomena **RGA** i **RGC**.

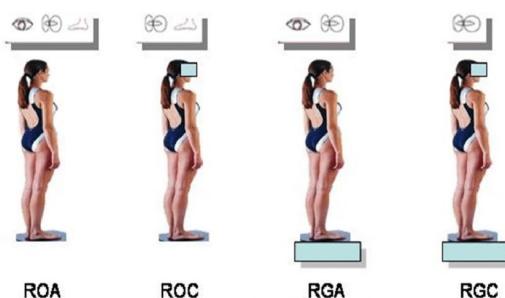


Fig. 1: Representació gràfica de les quatre condicions estudiades mitjançant el test de Romberg. [phdthesis]

La capacitat del pacient per mantenir l'equilibri, les oscil·lacions o les caigudes durant les dues fases de la prova (amb ulls oberts i tancats) proporciona informació clara a

l'especialista que realitza l'exploració. La prova de Romberg es considera **positiva** quan el pacient no aconsegueix mantenir l'equilibri amb els ulls tancats, això es veu reflectit en els índexs SOM, VIS i VEST amb valors baixos. En aquests casos, es diagnostica atàxia d'informació, que pot ser a causa d'un dèficit de la sensibilitat proprioceptiva, o bé a una disfunció del sistema vestibular.

3 CONJUNT DE DADES

Les dades de les que disposem són extretes del CAP central de Mataró. A la vegada que els especialistes del CAP recullen dades amb una plataforma de força mentre se'ls realitza el test, es col·loca als pacients un cinturó amb una IMU per a recollir dades dels mateixos pacients i durant les mateixes proves.

Les dades recollides amb la plataforma de força són processades per un programa d'ordinador anomenat NedSVE/IBV que finalment proporciona els indicadors de l'equilibri. El processament de les dades per a obtenir els indicadors és d'accés restringit i no disposem d'accés a aquest. És per això que partim de zero encara que ja existeixi un model per a estimar els paràmetres.

Tot i així les dades recollides per la plataforma de força i les recollides per la IMU no són iguals, encara que semblants. Així doncs es recullen dades amb una freqüència de 40 Hz, això correspon a 1200 dades per prova aproximadament, ja que cada prova té una durada aproximada de 30 segons.

A cada pacient se li realitza un número diferent de proves, però com a mínim una de cada: ROA, ROC, RGA i RGC. Per a crear el conjunt de dades, s'han separat les dades per proves creant així 4 conjunts de dades diferents.

El nostre objectiu és modelitzar les dades obtingudes per la IMU per a obtenir els mateixos indicadors que s'obtenen a partir del programa NedSVE/IBV amb les dades de força. Així doncs, les dades proporcionades pel CAP de la plataforma de força junt amb el programa són molt importants perquè ens permeten crear un *dataset* per a realitzar **aprenentatge supervisat**, ens proporcionen les etiquetes de les mostres.

Els indicadors que s'utilitzen com a etiqueta, com ja s'han mencionat anteriorment són els següents:

1. **Índex SOM:** Fa referència al percentatge de normalitat del sistema somato-sensorial en la contribució a l'equilibri.
2. **Índex VIS:** Fa referència al percentatge de normalitat del sistema visual en la contribució a l'equilibri.
3. **Índex VEST:** Fa referència al percentatge de normalitat del sistema vestibular en la contribució a l'equilibri.

Els índexs van de 0 a 100, on 0 indica poca estabilitat i falta d'equilibri i 100 cap alteració de l'equilibri. Per a crear els algorismes s'han reduït els tres indicadors en un factor de 100 per a tenir-los en el rang de 0 a 1 i simplificar la interpretació.

Com s'observa a la figura 70 les classes estan molt **desequilibrades**, gairebé totes les proves tenen un índex elevat.

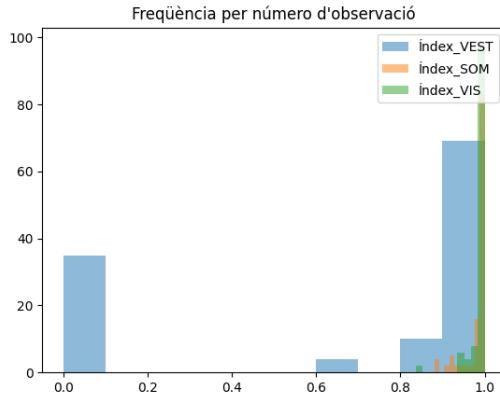


Fig. 2

L'índex VEST és l'únic on es presenten algunes proves positives. Això té sentit si tenim en compte que aquest índex s'ha obtingut amb el software NedSVE/IBV i aquest l'obté mitjançant el quotient entre el resultat de la prova RGC i la prova ROA. La primera prova sol ser aquella en la qual s'observen pitjors resultats ja que hi ha dos condicions alterades: la vista i el sòl. En canvi la primera prova sol ser aquella en la qual s'observen millors resultats ja que cap de les dues condicions és alterada. Per tant és coherent que sigui l'índex amb valors més baixos. És per això que es desenvoluparan els algoritmes amb aquest índex com a **variable objectiu**.

3.1 Processament dades plataforma de força

En aquesta secció s'expliquen les dades proporcionades pel CAP de Mataró, obtingudes amb una plataforma de força. Les dades es troben inicialment en un arxiu de tipus .csv, amb una primera fila amb les dades del pacient. Aquesta fila és molt important ja que conté els indicadors d'equilibri SOM, VIS i VEST, a més de les dades demogràfiques del pacient com edat, pes, sexe, etc.

De cada prova es disposa del desplaçament en l'eix de les x i en l'eix de les y. Per a la creació dels conjunts de dades s'ha unit cada prova amb els corresponents indicadors de l'equilibri, així disposem dels desplaçaments en els dos eixos, i tres variables objectiu a estimar.

Els conjunts de dades formats per aquestes dades tenen les següents dimensions:

TAULA 1: DESCRIPCIÓ DELS CONJUNTS DE DADES (PLATAFORMA FORÇA)

Prova	Mida	Valors nuls en les variable objectiu		
		Índex SOM	Índex VEST	Índex VIS
ROA	126 x 2 x 1119	0	8	0
ROC	124 x 2 x 1119	0	8	0
RGA	123 x 2 x 1199	0	8	0
RGC	115 x 2 x 1199	0	0	0

Per a cada mostra (una prova a un pacient) els dos vectors de desplaçament tenen 1199 valors, les dades estan capturades en 40 Hz com es descriu anteriorment. Creant una gràfica per a cada mostra del desplaçament en l'eix x i en l'eix y, veiem que és possible detectar a simple vista l'indici

de caiguda només en el cas de les proves RGC. Un exemple és el cas de la pacient amb identificador fg51f:

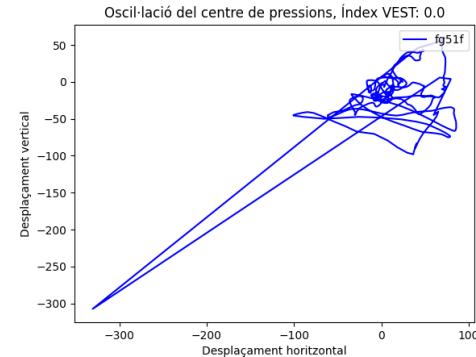


Fig. 3: Desplaçament d'una prova RGC amb índex VEST 0.0

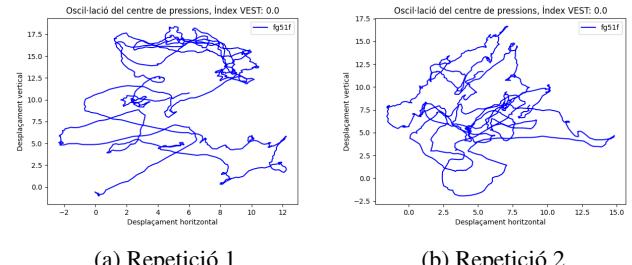


Fig. 4: Desplaçament de dues proves ROA realitzades a la pacient fg51f amb índex VEST 0.0

Observem com en la prova RGC (3) és fàcilment detectable l'índex VEST baix, en canvi en les dues repeticions de la prova ROA (4), no és detectable.

A l'apartat Gràfiques d'oscil·lació del centre de pressions (C.3) de l'apèndix es troben les gràfiques de moltes de les mostres de que disposem per a la creació dels algoritmes.

3.2 Processament dades IMU

Les dades capturades per la Unitat de Mesura Inercial són més riques i complexes, permetent realitzar ànalisis més sofisticats. Aquestes són mesurades en sistema hexadecimal i per a la seva modelació han estat passats al sistema decimal. En un primer intent de modelitzar-les mitjançant xarxes neuronals, la base d'aquestes dades ha estat creada amb els següents paràmetres extrets directament del document que genera la captura de dades amb la IMU: [6]

- Acceleròmetre:** en els tres eixos: x, y i z. Està compost per una massa suspesa en un receptacle que es mou en la direcció de la mesura. El desplaçament de la massa és proporcional a l'acceleració en aquesta direcció.
- Giroscopi:** en els tres eixos: x, y i z. Mesura les velocitats angulars de rotació del cos.
- Magnetòmetre:** en els tres eixos: x, y i z. És sensible al camp magnètic i s'utilitza per obtenir informació sobre l'orientació del cos respecte al nord magnètic terrestre.

4. **Vector de gravetat:** en els tres eixos: x, y i z. Ofereix informació sobre l'orientació i la direcció de la força de gravetat en els tres eixos.

Aquestes dades també han estat dividides per proves (ROA, ROC, RGA i RGC) per a disposar de més mostres. Cada una de les mostres està composta per 12 vectors de 1200 valors de llargada aproximadament. En funció del *dataset* s'han escurçat totes les mostres a la llargada de la mostra mes curta, per així tenir mostres uniformes. Els *datasets* finals tenen aquesta forma:

TAULA 2: DESCRIPCIÓ DELS CONJUNTS DE DADES (IMU)

Prova	Mida	Valors nuls en les variables objectiu		
		Índex SOM	Índex VEST	Índex VIS
ROA	103 x 12 x 1150	0	4	0
ROC	106 x 12 x 1022	0	4	0
RGA	106 x 12 x 1138	0	4	0
RGC	102 x 12 x 1127	0	0	0

Observem que en aquests *datasets* la quantitat de mostres és menor, i conseqüentment el nombre de valors nuls en la variable objectiu VEST també. Això es deu a que el CAP Mataró ha proporcionat algunes mostres de més que no es van arribar a mesurar amb la IMU. El tractament dels valors nuls ha estat eliminar totes les mostres amb l'índex VEST nul.

3.2.1 Trajectòria

Com s'explica més endavant, les característiques en brut de la IMU no són suficients per a estimar l'índex VEST. És per això que s'ha creat un programa Python per a processar les dades de l'acceleròmetre i el giroscopi per a obtenir una nova mesura més representativa del moviment: la trajectòria. Esperant que sigui més fàcil identificar un índex VEST baix a simple vista, com succeeix amb el desplaçament proporcionat per la plataforma de força.

Observant les gràfiques de les dades brutes del sensor MPU-9250 (5, 6) és molt difícil detectar un mal equilibri, i com s'explica més endavant, mitjançant xarxes neuronals també es difícil la identificació.

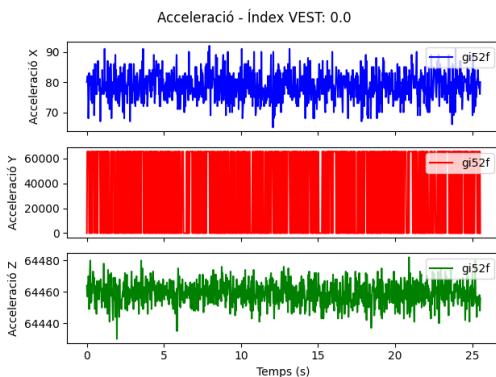


Fig. 5: Acceleració en brut durant la realització de la prova ROC.

El programa per obtenir la trajectòria ha estat desenvolupat a partir d'un algoritme d'estabilització AHRS (Attitude and Heading Reference System) [4] que processa i analitza

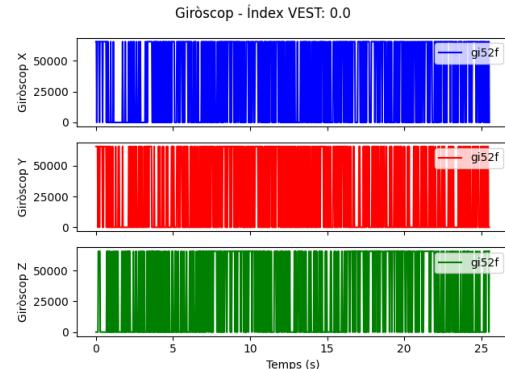


Fig. 6: Velocitat angular en brut durant la realització de la prova ROC.

les dades de l'acceleròmetre i el giroscopi proporcionades per la IMU amb sensor MPU-9250 amb una freqüència de 40 Hz. L'objectiu principal és estimar la posició i orientació tridimensional (trajectòria) de la IMU mentre es mou en l'espai.

Escalatge de dades

En primer lloc ha calgut realitzar un estudi de l'escala de les dades per a ajustar-les a les Unitats del Sistema Internacional per a poder confeccionar els càlculs amb coherència. A la descripció del sensor s'especifiquen els possibles rangs d'escala per a les dues característiques d'interès: per a l'acceleròmetre es poden calcular les dades amb un rang de $\pm 2g$, $\pm 4g$, $\pm 8g$ i $\pm 16g$ i per al giroscopi amb un rang de ± 250 , ± 500 , ± 1000 i ± 2000 °/seg. Les opcions programades han estat $\pm 16g$ i ± 2000 °/seg. La fórmula per a realitzar la conversió de les dades en brut és:

$$\text{valor escalat} = \frac{\text{valor en brut}}{2^{16} - 1} \times \text{rang màxim} \quad (1)$$

[2]

El denominador de la fórmula no és res més que el valor màxim enregistrat per a cada característica, que en el nostre cas és el mateix per ambdues. Finalment tenim les dades en acceleració gravitacional (g) i graus per segon (°/seg).

Estimació de les trajectòries utilitzant el Filtre AHRS

El funcionament del programa es basa en un bucle principal que itera sobre cada dada capturada pel sensor, és a dir es realitzen aproximadament 1200 iteracions. Abans de realitzar les iteracions s'inicialitza el filtre AHRS amb els paràmetres:

1. **SamplePeriod:** Indica el temps que transcurre entre cada mesura realitzada pel sensor. En el nostre cas és de 0.025 segons ja que la freqüència és de 40Hz.
2. **Kp:** És el guany proporcional del filtre. Aquesta constant controla la contribució de l'error actual d'orientació en la correcció realitzada pel filtre. Un valor més alt de "Kp" farà que el filtre respongui més ràpidament a l'error, però també pot introduir més soroll en l'estimació. Durant les iteracions estarà ajustat a zero perquè volem evitar canvis bruscs en l'orientació.

3. **Ki:** És el guany integral del filtre. Aquesta constant controla la contribució de l'error acumulat en el temps a la correcció realitzada pel filtre. Ajuda a eliminar l'error persistent que no es corregeix només amb el guany proporcional "Kp".

A cada iteració s'actualitza l'orientació mitjançant la funció *UpdateIMU* a cada pas de temps. Aquesta funció rep les dades de l'acceleròmetre i el giroscopi en els tres eixos per un instant de temps i calcula l'orientació estimada.

Un cop s'ha calculat la nova orientació, s'obté la representació matemàtica de la nova orientació del sistema en forma de quaternions. Aquests s'utilitzen per rotar un vector de referència, un vector unitari que s'inicialitza amb l'eix X. Això permet obtenir un nou vector que representa l'orientació actual del sistema.

Per a obtenir la posició només cal afegir el nou vector de referència, multiplicat pel període de mostreig, al vector de referència de la iteració anterior.

L'acumulació successiva d'aquests vectors resultants són el que anomenem trajectòria.

Càlcul de la orientació

En l'apartat anterior s'explica la obtenció de la trajectòria, per aconseguir-la és imprescindible el càlcul de la orientació del sistema. Aquesta es pot obtenir amb el filtre AHRS i les dades de l'acceleròmetre i el giroscopi. En primer lloc es normalitza la mesura de l'acceleròmetre per assegurar-se que té una magnitud de 1. En segon lloc es calcula l'error entre la direcció de la gravetat estimada i la mesurada, utilitzant quaternions. Inicialment la direcció estimada és aquella amb l'eix X apuntant cap a dalt, l'eix Y cap als costats i l'eix Z cap enfront, això s'aplica només a aquest experiment. En circumstàncies normals l'orientació inicial de la IMU és:

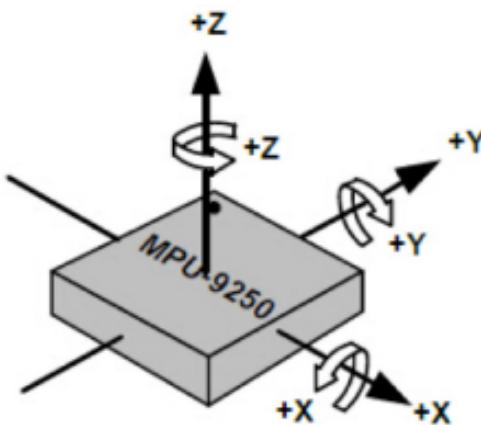


Fig. 7: Orientació estàndard del sistema de coordenades del sensor.

Aquest error representa la diferència entre l'orientació esperada i l'orientació real del sensor.

Seguidament es calcula la integral de l'error per tenir en compte els error acumulats al llarg del temps. Amb això es calcula un vector de control mitjançant les constants "Kp" i "Ki" multiplicades per l'error i la integral de l'error respecti-

tivament. Aquest vector representa la correcció que s'aplicarà a l'orientació actual.

Aquest vector també s'utilitza per a calcular la taxa de canvi de la orientació expressada en quaternions. Aquest càlcul proporciona el canvi en l'orientació del sensor en el pròxim instant de temps.

Finalment per a obtenir l'orientació estimada s'integra la taxa de canvi obtinguda anteriorment.

Aquest procés, com s'especifica a l'inici de la secció, es repeteix en cada mostreig (en cada instant de temps).

Un cop obtinguda la trajectòria, si creem una gràfica per mostra en 3D, podem veure que és més fàcil observar el comportament del pacient. Per exemple estudiem el comportament del pacient amb identificador *af51h* i resultat de la Prova de Romberg positiu:

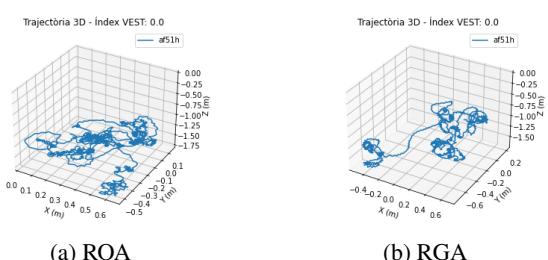


Fig. 8: Trajectòria del pacient *af51h* durant la realització de dues proves diferents.

Podem veure com el rang del recorregut és molt més ampli que en el cas d'una persona amb resultat negatiu, com és el cas del pacient amb identificador *ar51f*:

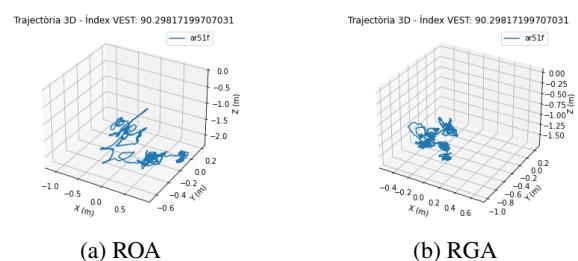


Fig. 9: Trajectòria del pacient *ar51f* durant la realització de dues proves diferents.

A l'apartat Gràfiques de la trajectòria obtinguda amb les dades de la IMU (B.4) de l'apèndix es troben les gràfiques de moltes de les mostres que s'han recollit amb la IMU per al modelatge.

4 MODELACIÓ DADES PLATAFORMA DE FORÇA

Modelar les dades de la plataforma de força no té cap utilitat en si per l'objectiu del treball però pot ajudar-nos a fer una idea de la utilitat del conjunt de dades.

Per a modelar aquests conjunts de dades s'han creat dues estructures amb el mateix cos central:

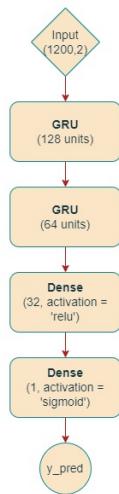


Fig. 10: Arquitectura dels 2 models per a les dades de la plataforma de força.

La primera xarxa consisteix en l'arquitectura descrita al diagrama (10), entrenada amb les dades "brutes" del desplaçament, però normalitzades. La segona xarxa consisteix en utilitzar un *Autoencoder* per reduir la dimensionalitat de les seqüències ja que són molt llargues (aproximadament 1200 valors per cada eix). En altres paraules, s'entrena una xarxa neuronal *Autoencoder* per aprendre a representar els vectors de desplaçament amb menys punts, i després s'utilitza aquesta representació codificada per entrenar la xarxa descrita al diagrama (10).

4.0.1 Resultats

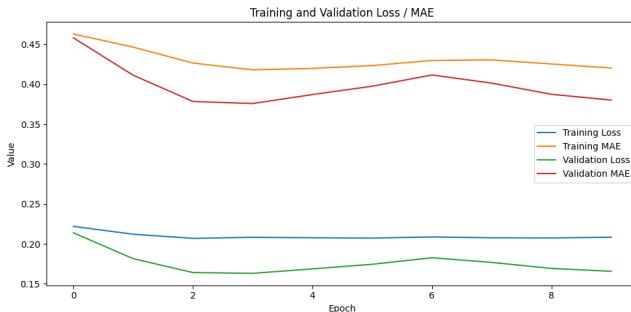


Fig. 11: Evolució de la pèrdua i la mitjana de l'error absolut durant l'entrenament i la validació de la xarxa entrenada amb les dades brutes de la plataforma de força.

Només tenint en compte els valors de l'error absolut mitjà i de la pèrdua pot semblar que la xarxa ha assolit un bon rendiment ja que els valors són petits i s'observa un lleuger descens.

Tot i així, si realitzem algunes prediccions (3) amb mostres del conjunt de test, observem que la xarxa només ha après a generar gairebé sempre la mateixa sortida, una sortida que no s'allunyi gaire de cap dels valors més repetits.

Exactament el mateix succeeix amb el resultat de la xarxa entrenada amb les dades escurçades:

Predictió	Valor Real
0.6626099	1.0
0.62722147	1.0
0.84453857	0.0
0.66952425	1.0
0.660738	1.0
0.64422446	1.0
0.6469535	1.0
0.6113506	0.0
0.65072644	0.0
0.6452255	0.83178806
0.6572629	0.83178806
0.63271946	1.0
0.67229617	1.0
0.64583224	1.0
0.67226225	1.0
0.6735447	1.0
0.6719206	1.0

TAULA 3: RESULTATS DE LA PREDICCIÓ VS. VALORS REALS DE LA XARXA ENTRENADA AMB LES DADES BRUTES.

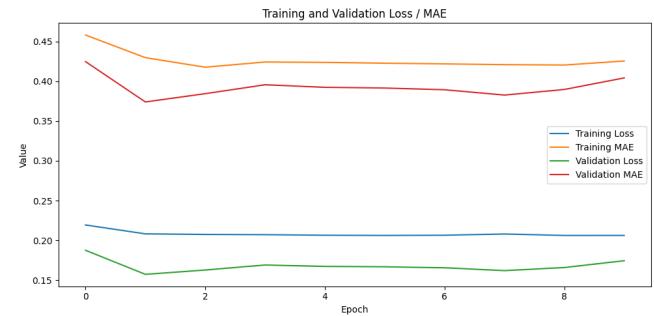


Fig. 12: Evolució de la pèrdua i la mitjana de l'error absolut durant l'entrenament i la validació de la xarxa entrenada amb les dades escurçades per un *Autoencoder*.

Predictió	Valor Real
0.61353284	1.0
0.61214185	1.0
0.67903984	0.0
0.6183259	1.0
0.62093383	1.0
0.61723983	1.0
0.6230222	1.0
0.60034037	0.0
0.613134	0.0
0.6046908	0.83178806
0.62135875	0.83178806
0.5865107	1.0
0.613028	1.0
0.6088542	1.0
0.6265381	1.0
0.6190733	1.0
0.6163875	1.0

TAULA 4: RESULTATS DE LA PREDICCIÓ VS. VALORS REALS DE LA XARXA ENTRENADA AMB LES DADES ES-CURÇADES.

Sembla que és molt difícil, si no impossible, crear una xarxa neuronal que estimi amb un error relatiu petit l'índex d'e-

equilibri VEST, a partir de les dades prou representatives del desplaçament. Tot i així, als següents apartats es realitza una cerca més exhaustiva d'una xarxa neuronal per a modelar les dades capturades per la IMU i obtenir una estimació de l'índex VEST.

5 MODELACIÓ DADES IMU

5.1 LSTM combinada amb dades brutes

S'han realitzat diferents models de xarxes neuronals per a intentar predir l'índex VEST. El primer model consisteix en la unió de quatre xarxes de tipus LSTM, cadascuna per a processar una de les característiques recollides per la IMU: l'acceleració, el giroscopi, el magnetòmetre i el vector de gravetat.

Per assegurar-nos que totes les característiques estiguin en la mateixa escala, s'ha utilitzat una funció que pren dades en format tridimensional, les redimensiona a un format bidimensional per a aplicar la normalització *min-max scaling* amb la funció *MinMaxScaler* de la biblioteca *scikit-learn* i després les torna a redimensionar al format original.

Així doncs en aquest primer intent de modelització les dades són en **brut**, només s'hi ha aplicat una normalització.

Les 4 xarxes per característiques estan formades per una capa **Long Short Term Memory** que rep els tres vectors de característiques (un per cada eix), una capa *Dropout* per a regularitzar el model i prevenir el sobreajustament, amb una probabilitat de desactivació de cada neurona del 30% i finalment una capa totalment connectada amb una sola neuronal (*Dense layer*). Aquesta última capa proporciona la sortida del model individual, un valor entre 0 i 1 ja que s'utilitza l'activació **sigmoidal**.

Un cop entrenades les 4 xarxes individualment s'utilitza la funció *Concatenate* de la llibreria Keras per concatenar les capes LSTM i crear una xarxa neuronal més profunda i complexa, també de tipus Long Short Term Memory. Aquesta xarxa ha estat entrenada amb uns pesos inicials personalitzats que donen més pes a les mostres amb índex 0, ja que és la classe minoritària als *datasets*.

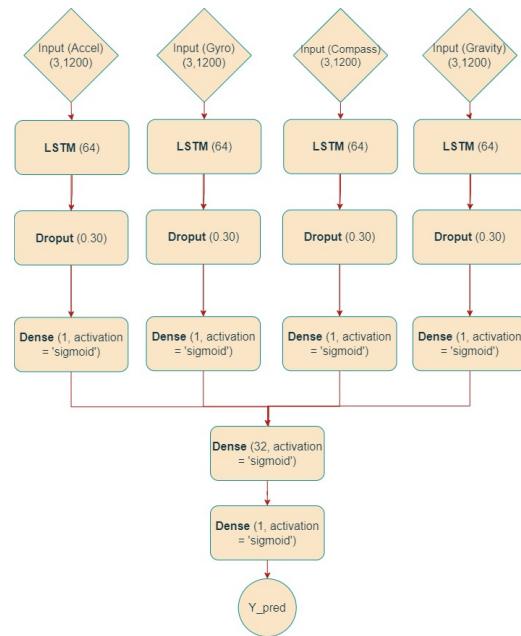


Fig. 13: Arquitectura model LSTM combinat.

5.1.1 Resultats

Com que les mostres estan molt desequilibrades, l'idoni seria avaluar l'efectivitat de la xarxa mitjançant una matriu de confusió. Això, però no és possible ja que les variables objectiu són contínues i no categòriques. Així doncs, ara per ara l'avaluarem amb l'**error quadràtic mitjà**. Aquesta mesura de rendiment és adequada per el nostre cas ja que a diferència d'altres mètriques té en compte la diferència exacta entre els valors predicts i els valors reals, sense importar si són alts o baixos, i no només el número d'encerts.

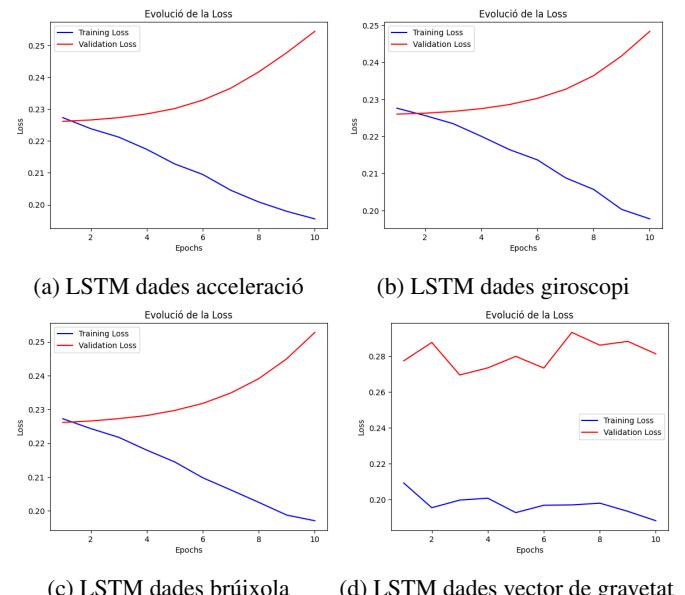


Fig. 14: Evolució de la mesura de rendiment de les 4 xarxes individuals.

Observem que les característiques en brut individualment no són suficients per a estimar l'índex VEST. Encara que el valor de la mètrica no sigui gaire alt, quan es canvia de mode de la xarxa i es passa al mode d'avaluar, el valor en 3 de les 4 xarxes augmenta. Això indica que el model està memo-

ritzant les dades d'entrenament en lloc d'aprendre patrons generals que s'apliquen a altres dades. En el cas de la xarxa LSTM entrenada amb les dades del vector de gravetat (14d), també es produeix un sobre-ajust a les dades d'entrenament ja que el valor de la mètrica en l'avaluació és major que durant l'entrenament.

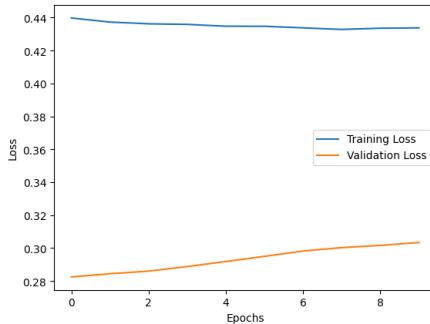


Fig. 15: Evolució de la mesura de rendiment en la xarxa composta

El resultat de l'entrenament i la validació de la xarxa combinada és el que es mostra al gràfic 15. Aquests valors finals mostren que durant l'entrenament de la xarxa neuronal, la pèrdua (*loss*) disminueix gradualment tant en el conjunt d'entrenament com en el conjunt de validació. Això hauria d'indicar que el model està aprenent però només cal fer una predicción d'un conjunt de mostres per veure que el que realment està aprenent la xarxa és a generar la mateixa sortida per a totes les entrades, una sortida que no s'allunya gaire ni de les mostres amb índex baix ni de les mostres amb índex alt. A la següent taula es mostra un exemple de prediccions generades per la xarxa per a 16 mostres del conjunt de validació.

Predictió	Valor Real
0.3387403	1.0
0.33873442	1.0
0.33873516	1.0
0.33873641	1.0
0.33874255	0.0
0.33874223	0.0
0.33874553	0.0
0.33880907	1.0
0.33874246	1.0
0.33874598	1.0
0.3387459	1.0
0.33873883	0.6449064
0.33873934	0.6449064
0.33879846	0.0
0.33874768	0.0
0.33873776	1.0

TAULA 5: RESULTATS DE LA PREDICCIÓ VS. VALORS REALS

5.2 RNN entrenades amb la trajectòria

Per al modelatge de la trajectòria, s'ha emprat com a arquitectura principal una Xarxa Neuronal Recurrent (RNN), ja que són les més adequades per a tractar seqüències de dades amb dependències temporals. Les RNN són capaces

de capturar les correlacions i tendències ocultes presents en les dades de la trajectòria, essent una elecció òptima per a processar les seqüències de tres vectors que representen els punts de la trajectòria a diferents instants de temps.

La RNN és una xarxa neuronal que incorpora una realimentació dades, permetent que les sortides d'una etapa de temps anterior siguin utilitzades com a entrada per a l'etapa de temps actual. Aquest mecanisme habilita la memòria de la xarxa per emmagatzemar i processar seqüències llargues amb dependències temporals.

Abans d'entrenar cap xarxa ja podem preveure que no serà fàcil obtenir bon rendiment ja que els conjunts de dades són molt petits i les classes estan molt desbalancejades. És per això que a més a més de provar diferents tipus d'arquitectures RNN, tindrem dos enfocaments: estimació de l'índex com a valor continu, classificació binària entre Classe 1: mostra positiva (índex VEST inferior a 50) i Classe 2: mostra negativa (índex VEST superior a 50).

Finalment, s'han creat 4 xarxes neuronals diferents:

1. GRU per regressió
2. GRU per classificació binària
3. LSTM per regressió
4. LSTM per classificació binària

L'arquitectura principal de les 4 xarxes és molt similar. La primera capa es tracta d'una capa LSTM/GRU amb 32, 64 o 128 unitats, la segona capa torna a ser LSTM/GRU amb 16, 32 o 64, la sortida d'aquesta està connectada totalment a una capa *Dense* amb 8, 16 o 32 neurones i finalment depenen si es tracta de regressió o de classificació binària, la última capa estarà formada per una capa *Dense* d'1 o de 2 unitats respectivament. En el cas de la regressió la funció d'activació d'aquesta última capa és la funció Sigmoid i en el cas de la classificació binària la funció SoftMax ja que aquesta proporciona probabilitats.

En la figura (16) es representa l'esquema de la xarxa de tipus GRU que realitza una classificació binària.

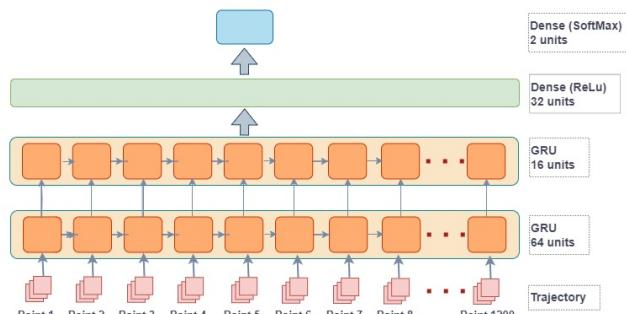


Fig. 16: Arquitectura xarxa GRU per la trajectòria.

Tant el nombre d'unitats de les capes com el Learning Rate, el número de batches i número d'epochs, han estat definits per cada xarxa mitjançant una cerca exhaustiva amb la tècnica **Cross Validation**, concretament amb la funció *RandomizedSearchCV* de la llibreria *Scikit-learn*. Aquesta

funció serveix per realitzar una cerca aleatòria dins els valors dels hiperparàmetres especificats per l'usuari. Té com a objectiu trobar la millor combinació d'hiperparàmetres per al model determinat.

Per a trobar la millor combinació les mostres d'entrenament es divideixen en un nombre n especificat de grups (en aquest cas 3), s'entrena el model per cada valor dels hiperparàmetres en $n-1$ subconjunts de les mostres i es valida el resultat amb el subconjunt restant.

En aquest tipus de Cross Validation només es proven certes combinacions aleatòries dels hiperparàmetres específics, per optimitzar el temps computacional. [7]

5.2.1 Resultats

Model	gru_units	gru_units2	dense_units	lr
GRU reg.	32	16	32	0.01
GRU class. bin.	64	16	8	0.01
LSTM reg.	32	64	32	0.01
LSTM class. bin.	128	32	32	0.001

TAULA 6: PARÀMETRES GUANYADORS EN LA CERCA D'HIPERPARÀMETRES PER CV

Model	Batches	Epochs
GRU per regressió	16	20
GRU per class. binària	32	40
LSTM per regressió	64	20
LSTM per class. binària	32	30

TAULA 7: PARÀMETRES GUANYADORS EN LA CERCA D'HIPERPARÀMETRES PER CV

Model	Loss	Mètrica
GRU per regressió	0.2044	0.3966 (MAE)
GRU per classificació binària	0.8424	0.6666 (Accuracy)
LSTM per regressió	0.2179	0.4138 (MAE)
LSTM per classificació binària	0.6997	0.6190 (Accuracy)

TAULA 8: RENDIMENT DELS MODELS AMB ELS PARÀMETRES TROBATS

En les xarxes anteriors s'ha vist que no és suficient analitzar la pèrdua i la mètrica per treure conclusions del rendiment de la xarxa, cal fer un anàlisi més exhaustiu, aquest varia entre les xarxes que generen una sortida continua i les que fan classificació binària.

Per les de regressió, generant una predició d'algunes mostres del conjunt de prova n'hi ha prou. Com es mostra a les taules (9) i (10) la xarxa aprèn de nou a generar una sortida gairebé idèntica en cada predició.

El rendiment de les xarxes per classificació binària es pot estudiar mitjançant la creació de la matriu de confusió.

A la figura (17) es veu de manera clara que la majoria de mostres positives no són detectades, és a dir hi ha una taxa molt alta de **False Negatives**. En l'àmbit de la medicina aquest és el pitjor escenari perquè la xarxa no estaria detectant el risc de malaltia.

Predictió	Valor Real
0.6151087	0.0
0.69594496	0.8569766235351562
0.66758496	1.0
0.7172315	0.9870536804199219
0.7013795	0.6351990127563476
0.54390967	1.0
0.69071686	0.0
0.67489606	1.0
0.62560946	0.9744159698486328
0.6653189	0.0

TAULA 9: RESULTATS DE LA PREDICCIÓ VS. VALORS REALS DE LA XARXA GRU PER REGRESSIÓ

Predictió	Valor Real
0.5473713	0.0
0.6927975	0.8569766235351562
0.58259284	1.0
0.7484456	0.9870536804199219
0.70936555	0.6351990127563476
0.50573206	1.0
0.6714604	0.0
0.58688796	1.0
0.5436399	0.9744159698486328
0.6129056	0.0

TAULA 10: RESULTATS DE LA PREDICCIÓ VS. VALORS REALS DE LA XARXA LSTM PER REGRESSIÓ

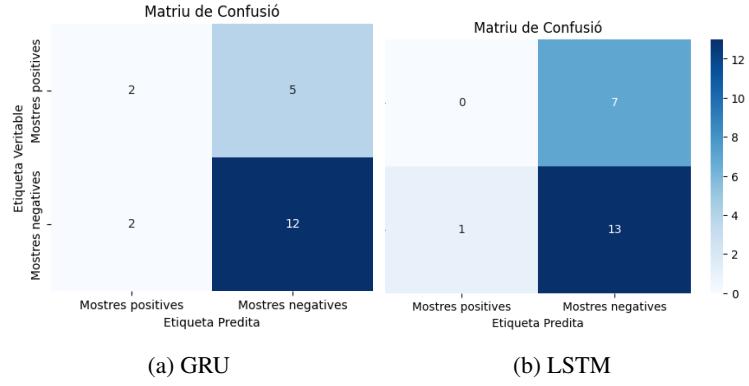


Fig. 17: Matrius de confussió de les dues xarxes que realitzen classificació binària.

6 CONCLUSIONS I PROPOSTES DE MILLORA

En conclusió, el desenvolupament d'algoritmes per estimar l'indicador d'equilibri amb el conjunt de dades actual ha demostrat ser un repte complex i potencialment difícil de resoldre amb les arquitectures LSTM i GRU utilitzades. La manca de mostres i el desequilibri entre classes han limitat el rendiment dels models, s'ha demostrat que es necessita un conjunt de dades més gran per obtenir resultats satisfactoris.

No obstant això, és important destacar que els algoritmes han estat implementats i podran ser re-entrenats en un futur amb un conjunt de dades més extens. Això podria conduir a una millora significativa del rendiment i a l'assoliment de l'objectiu principal: proporcionar una solució més econòmica i accessible per a un primer diagnòstic de l'equilibri

dels pacients.

Així doncs, per millorar aquest treball, és essencial augmentar el conjunt de dades i equilibrar les classes per millorar la generalització dels models. També es podria fer una recerca de *datasets* similars però més extensos i entrenar els models generats amb ells.

Amb aquestes millores, es preveu que l'aplicació tingui un impacte significatiu en la detecció precoç de malalties i en l'avaluació de l'equilibri en diverses situacions clíniques i d'investigació.

7 APLICACIONES

A mesura que avancin els mesos es recolliran més mostres i s'aconseguirà un *dataset* més robust amb més mostres positives (amb un índex de l'equilibri baix) i segurament els models creats milloraran el seu rendiment. Un cop s'hagi aconseguit obtenir un error significativament baix, el model adequat, ja sigui de regressió o de classificació binària, serà útil per realitzar un primer diagnòstic de l'equilibri en aquelles persones amb risc de tenir un equilibri deficient.

El procediment podria ser el que s'explica al diagrama (18).

D'aquesta manera s'aconsegueix substituir el dispositiu mèdic de la plataforma de força, que costa milers d'euros, per un dispositiu portable amb un cost de 100 euros aproximadament.

AGRAÏMENTS

Els agraiements són una part fonamental d'aquest treball, ja que sense el suport i col·laboració de diverses persones, aquesta investigació no hauria estat possible.

En primer lloc, vull expressar el meu sincer agraiement al meu tutor de Treball de Final de Grau, el Sr. Marc Codina Barberà, per haver-me donat l'oportunitat de realitzar aquest treball. La seva idea i la recopilació de dades al CAP de Mataró han estat essencials per al desenvolupament d'aquesta recerca. A més, vull agrair-li la confiança que ha dipositat en mi des del primer dia i la llibertat que m'ha atorgat per dur a terme la investigació.

També desitjo expressar el meu reconeixement als meus estimats pares. Gràcies a ells, sempre he tingut un suport incondicional, un plat a taula i cap mancança de primera necessitat, el que m'ha permès dedicar tots els meus esforços a aquest projecte.

Convé destacar l'entusiasme i suport constant de la meva estimada àvia, la Sibylle Hunzinger. La seva motivació i interès en els meus treballs i assoliments han estat un constant impuls per a seguir treballant amb il·lusió i recordant la sort que tinc de realitzar estudis tan apassionants i amb potencial per aportar valor a la societat.

Per últim i per descomptat vull donar les gràcies al meu company, Josep Puig, per sempre animar-me a ser una millor persona i donar el millor de mi mateixa. Aquest treball és un reflex d'aquesta perseverança, ja que quan em troava desmotivada o sense ganas de continuar, sempre ha estat

present per recordar-me la importància del treball i l'esforç en aquesta vida.

REFERÈNCIES

- [1] *13 resultados para 'imu+sensor'*. <https://tinyurl.com/amazon-price-imu>. n.d.
- [2] *Accelerometer, Gyroscope, and Magnetometer Analysis with Raspberry Pi Part I: Basic Readings*. 2022, November 16. URL: <https://makersportal.com/blog/2019/11/11/raspberry-pi-python-accelerometer-gyroscope-magnetometer#interfacing>.
- [3] *Como elegir una plataforma de fuerza AMTI*. <https://tinyurl.com/plataforma-de-fuerza>. n.d.
- [4] *Gait Tracking With x-IMU*. URL: <https://github.com/xioTechnologies/GaitTracking-With-x-IMU>.
- [5] Dr. Alberto Andrés Gómez. *Vertigo and Dizziness - Test de Romberg*. 2004. URL: <https://www.gaes.es/enfermedades-oido/infecciones-problemas-oido/vertigo-y-mareos/test-de-romberg>.
- [6] *IMU Working Principles: Technaid - Leading Motion*. n.d. URL: <https://web.archive.org/web/20171116190036/http://www.technaid.com/support/research/imu-working-principles/>.
- [7] *sklearn.model_selection.RandomizedSearchCV*. URL: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.RandomizedSearchCV.html.

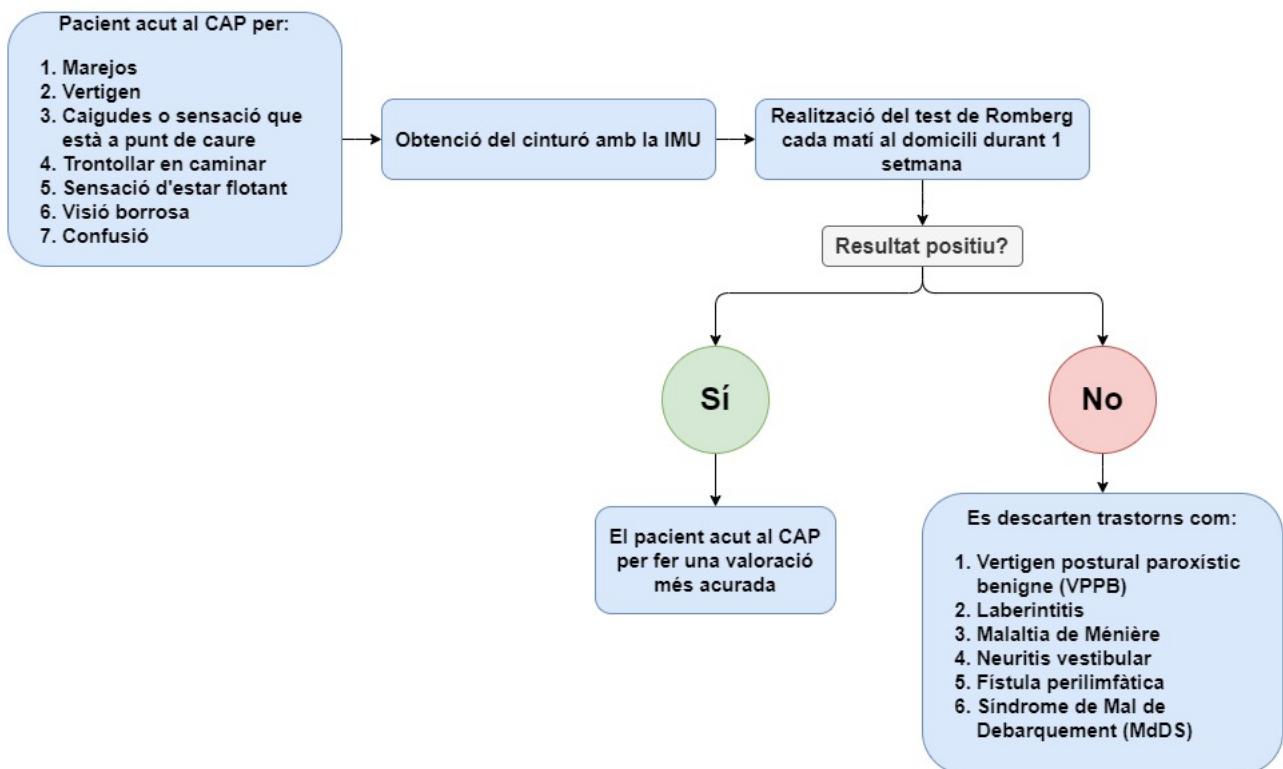


Fig. 18: Procediment en cas de símptomes de mal equilibri

APÈNDIX

A.1 Implementació filtre AHRS a partir de dades de la IMU per obtenir l'orientació en Python

```

class AHRS:
    def __init__(self, SamplePeriod, Kp, Ki):
        self.SamplePeriod = SamplePeriod
        self.Kp = Kp
        self.Ki = Ki
        self.q = np.array([-0.5, 0.5, 0.5, -0.5]) # Initial quaternion
        self.IntError = np.zeros(3)

    def quaternProd(self, a, b):
        ab = np.zeros(4)
        ab[0] = a[0] * b[0] - a[1] * b[1] - a[2] * b[2] - a[3] * b[3]
        ab[1] = a[0] * b[1] + a[1] * b[0] + a[2] * b[3] - a[3] * b[2]
        ab[2] = a[0] * b[2] - a[1] * b[3] + a[2] * b[0] + a[3] * b[1]
        ab[3] = a[0] * b[3] + a[1] * b[2] - a[2] * b[1] + a[3] * b[0]
        return ab

    def quaternConj(self, q):
        qConj = np.zeros(4)
        qConj[0] = q[0]
        qConj[1:] = -q[1:]
        return qConj

    def UpdateIMU(self, Gyroscope, Accelerometer):
        # Normalise accelerometer measurement
        if np.linalg.norm(Accelerometer) == 0:
            print('Accelerometer magnitude is zero. Algorithm update aborted.')
            return
        else:
            Accelerometer = Accelerometer / np.linalg.norm(Accelerometer)

        # Compute error between estimated and measured direction of gravity
        v = np.array([2 * (self.q[1] * self.q[3] - self.q[0] * self.q[2]),
                     2 * (self.q[0] * self.q[1] + self.q[2] * self.q[3]),
                     self.q[0]**2 - self.q[1]**2 - self.q[2]**2 + self.q[3]**2]) # estimated direction of gravity
        error = np.cross(v, Accelerometer)

        self.IntError = self.IntError + error # compute integral feedback terms (only outside of init period)

        # Apply feedback terms
        Ref = Gyroscope - (self.Kp * error + self.Ki * self.IntError)

        # Compute rate of change of quaternion
        pDot = 0.5 * self.quaternProd(self.q, np.array([0, Ref[0], Ref[1], Ref[2]]))

        self.q = self.q + pDot * self.SamplePeriod # integrate rate of change of quaternion

        self.q = self.q / np.linalg.norm(self.q) # normalise quaternion

        # Store conjugate
        self.Quaternion = self.quaternConj(self.q)
        return self.q

```

Fig. 19: Descripción del código.

B.2 Repositori GitHub amb el codi font

Per visitar el repositori feu clic aquí.

C.3 Gràfiques d'oscil·lació del centre de pressions

En aquesta secció d'apèndix es troben les gràfiques del desplaçament d'alguns pacients sobre la plataforma de força.

C.3.1 Gràfiques prova ROA

C.3.2 Mostres negatives

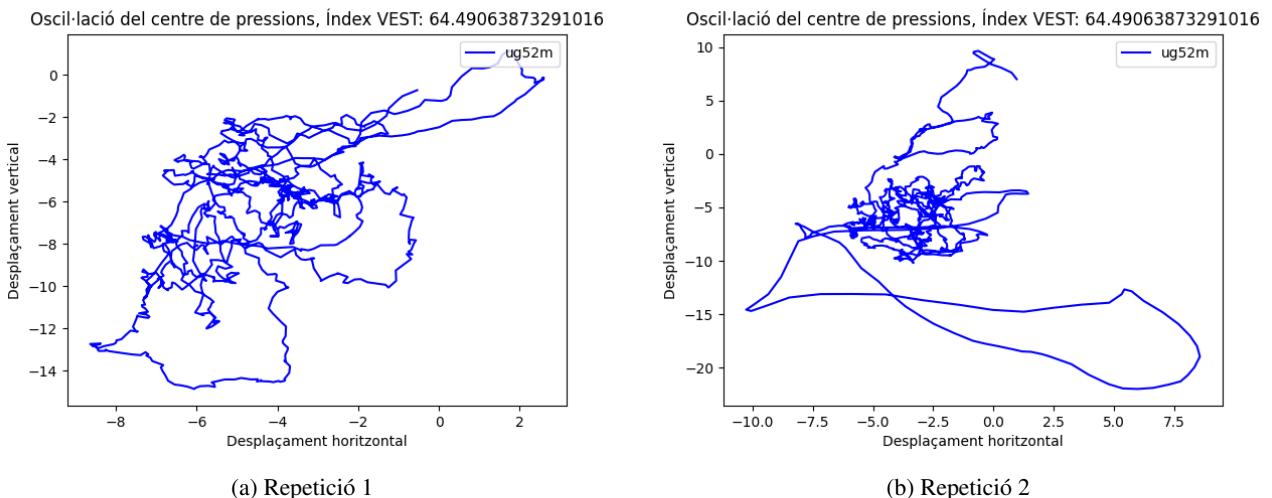


Fig. 20: Desplaçament de dues proves ROA realitzades al mateix pacient amb índex VEST 64.50

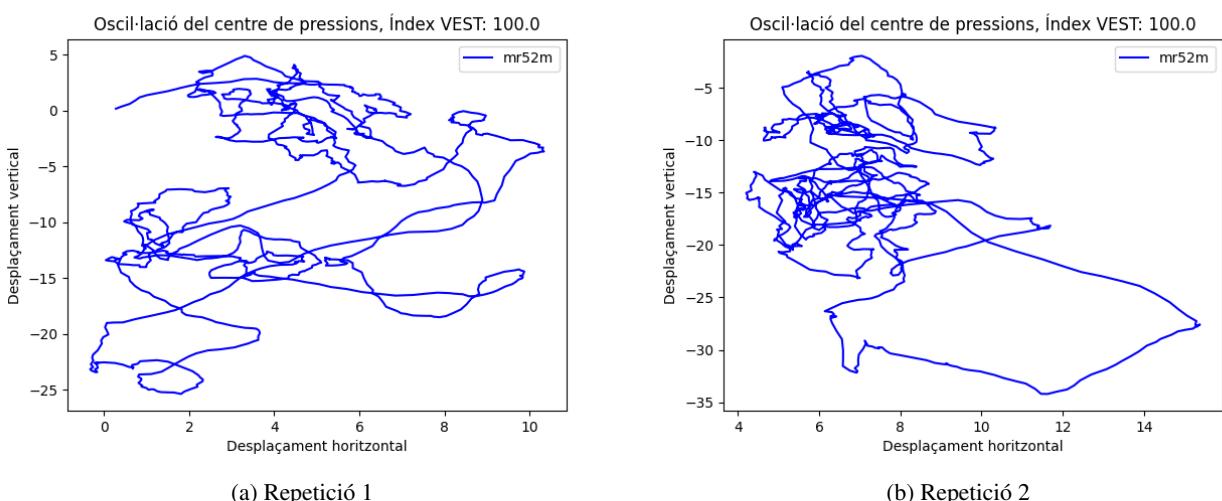


Fig. 21: Desplaçament de dues proves ROA realitzades al mateix pacient amb índex VEST 100

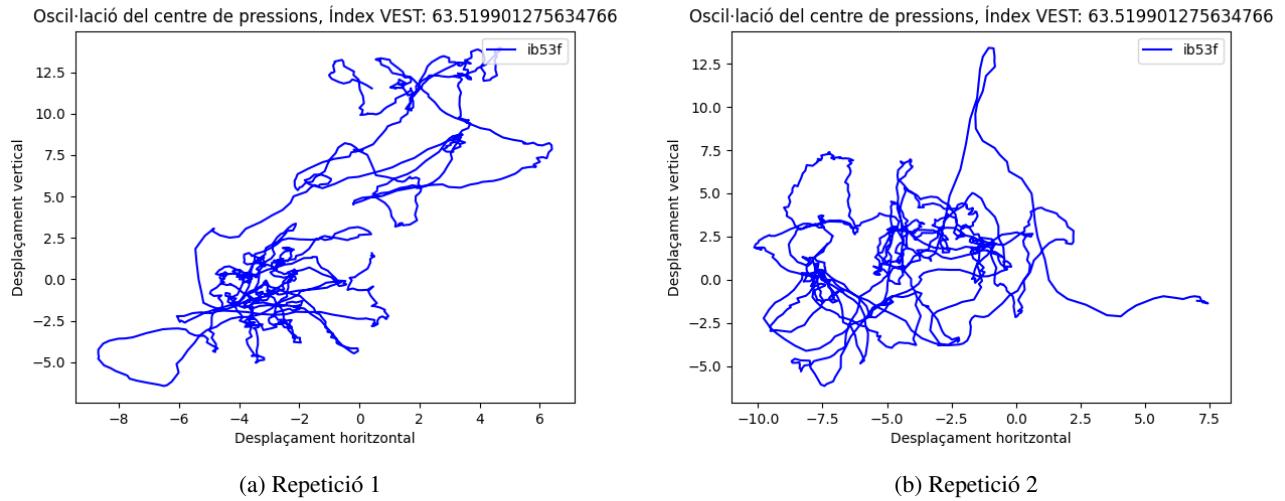


Fig. 22: Desplaçament de dues proves ROA realitzades al mateix pacient amb índex VEST 63.52

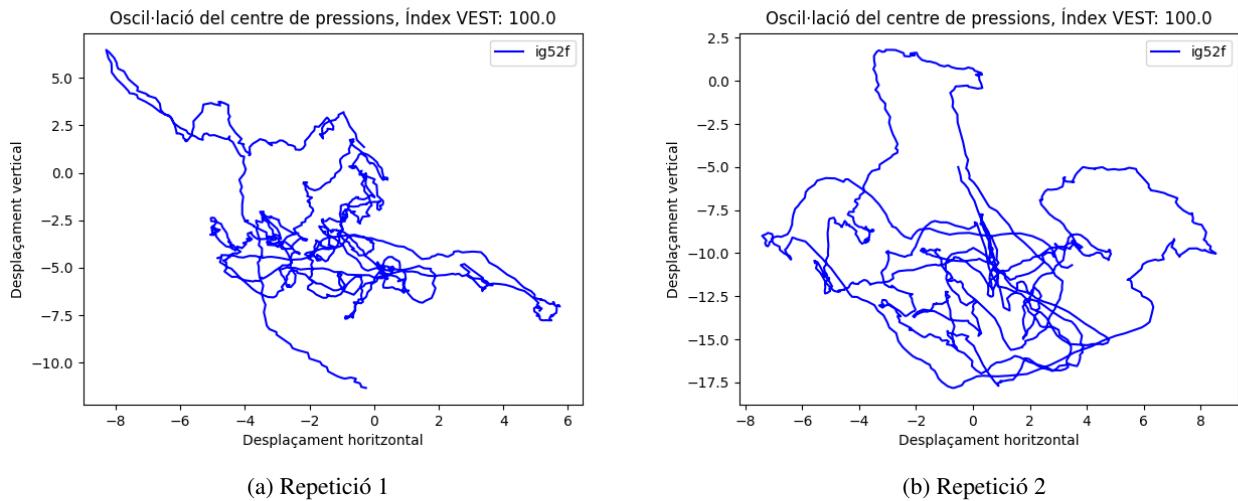


Fig. 23: Desplaçament de dues proves ROA realitzades al mateix pacient amb índex VEST 100

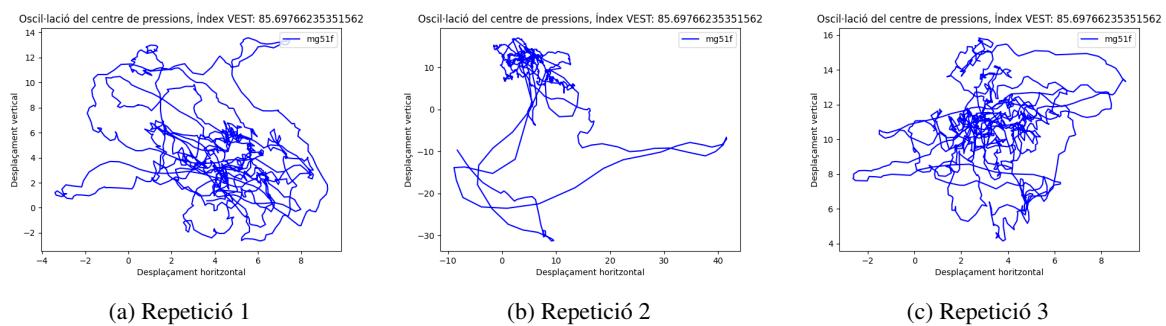


Fig. 24: Desplaçament de tres proves ROA realitzades al mateix pacient amb índex VEST 85.69

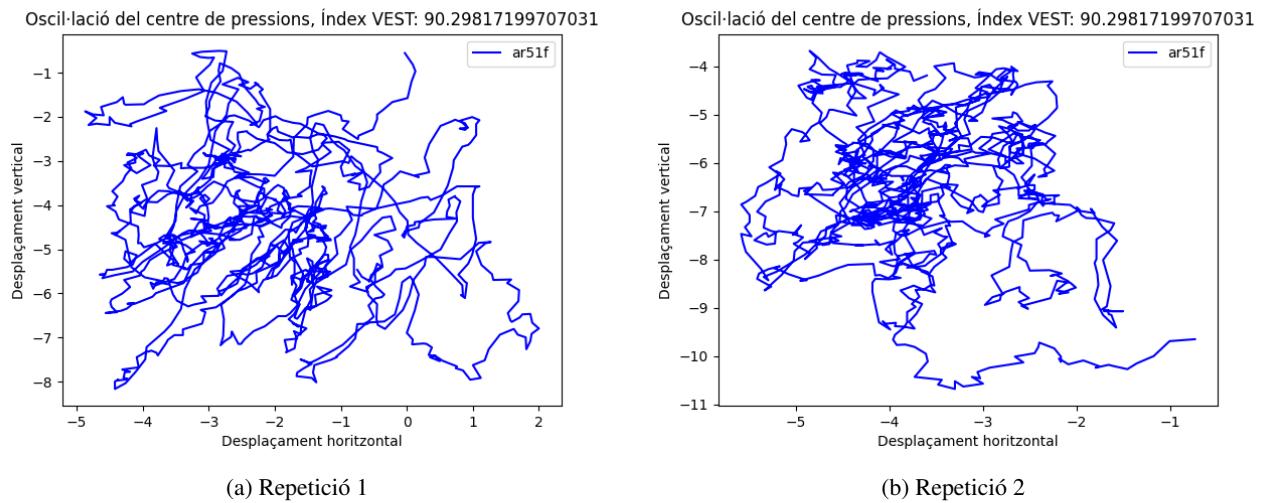


Fig. 25: Desplaçament de dues proves ROA realitzades al mateix pacient amb índex VEST 97.44

C.3.3 Mostres positives

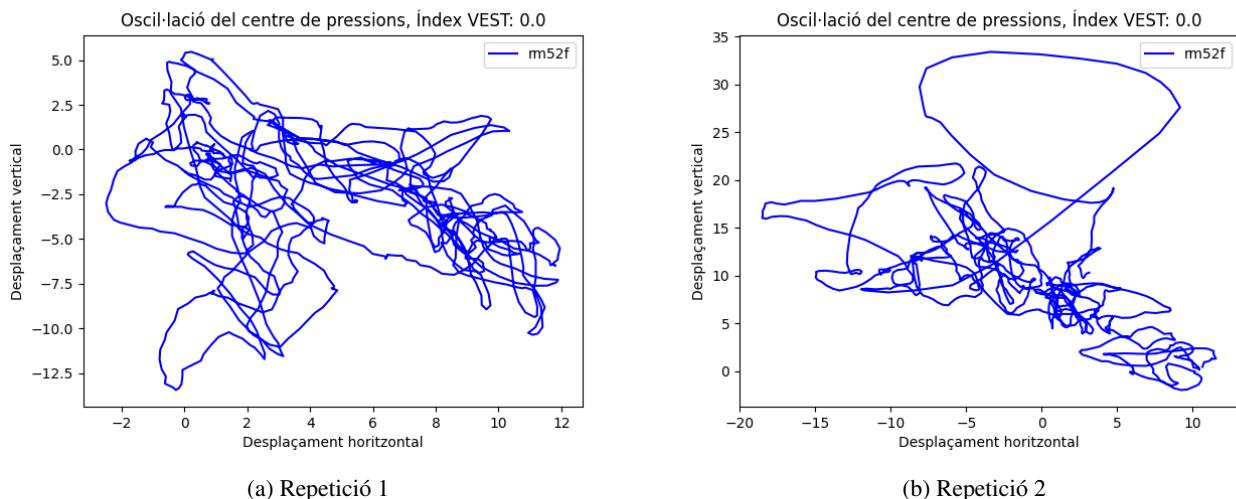


Fig. 26: Desplaçament de dues proves ROA realitzades al mateix pacient amb índex VEST 0.0

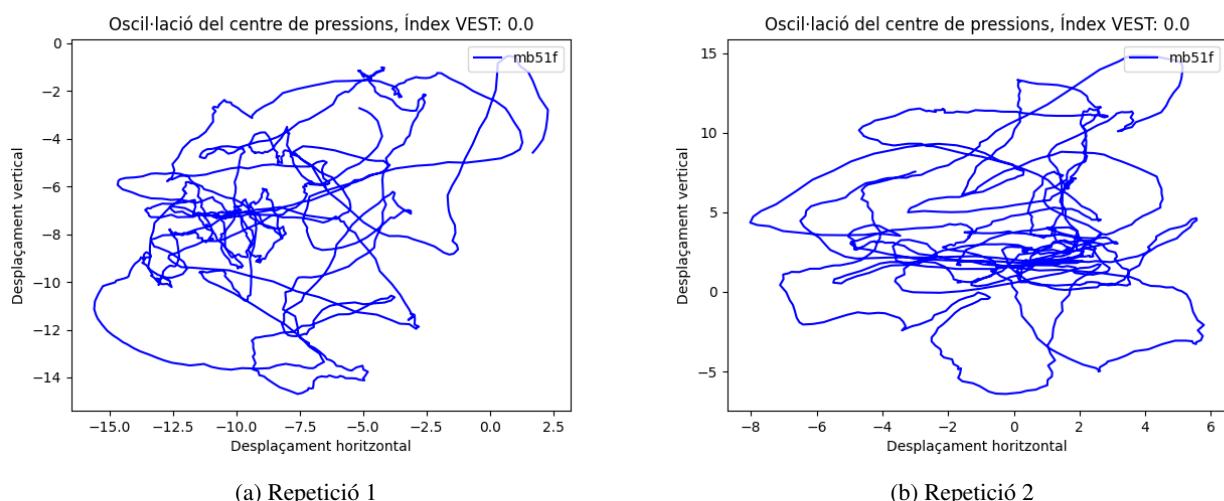


Fig. 27: Desplaçament de dues proves ROA realitzades al mateix pacient amb índex VEST 0.0

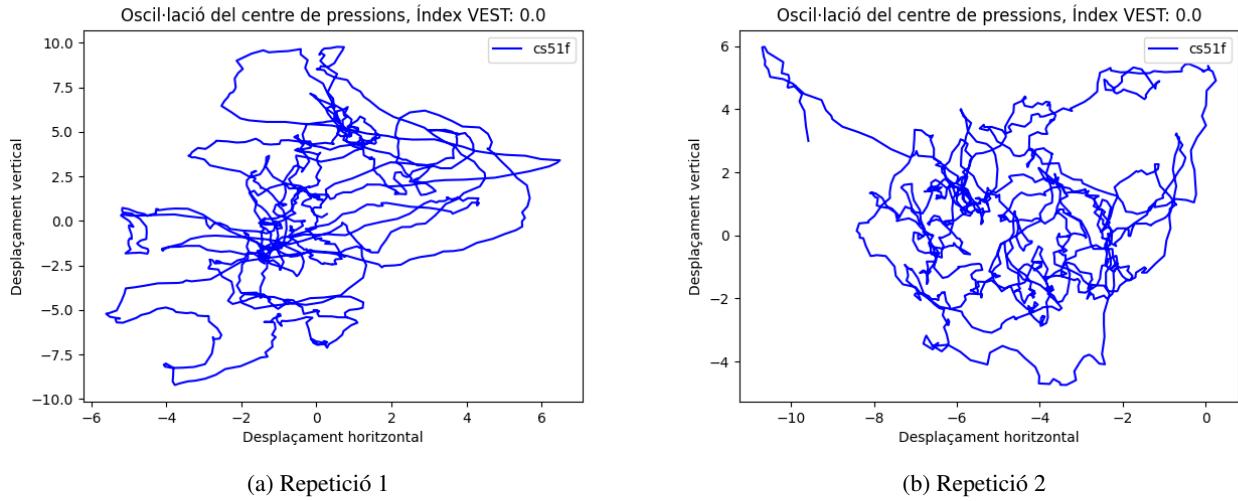


Fig. 28: Desplaçament de dues proves ROA realitzades al mateix pacient amb índex VEST 0.0

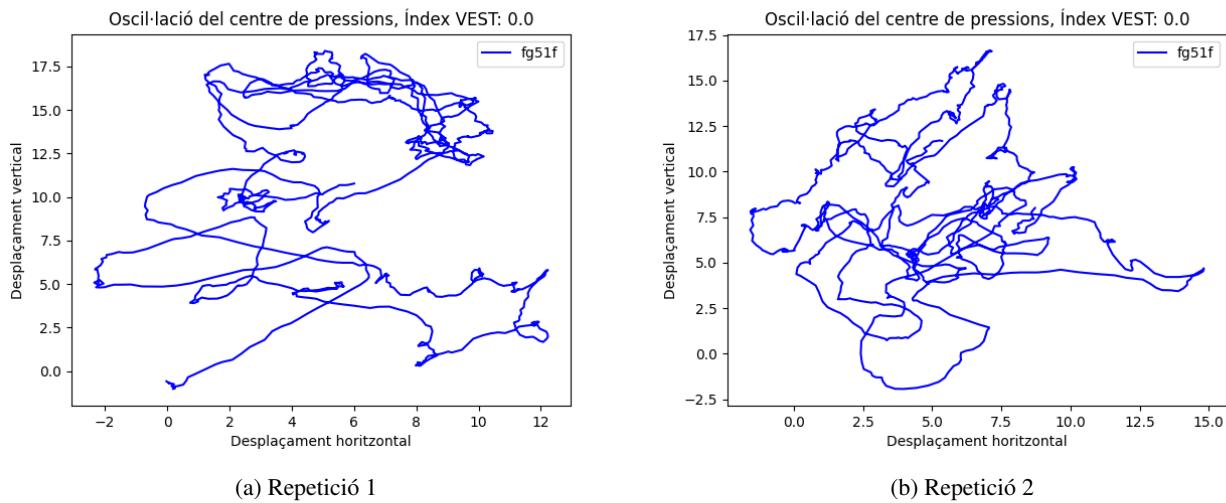


Fig. 29: Desplaçament de dues proves ROA realitzades al mateix pacient amb índex VEST 0.0

C.3.4 Gràfiques prova ROC

C.3.5 Mostres negatives

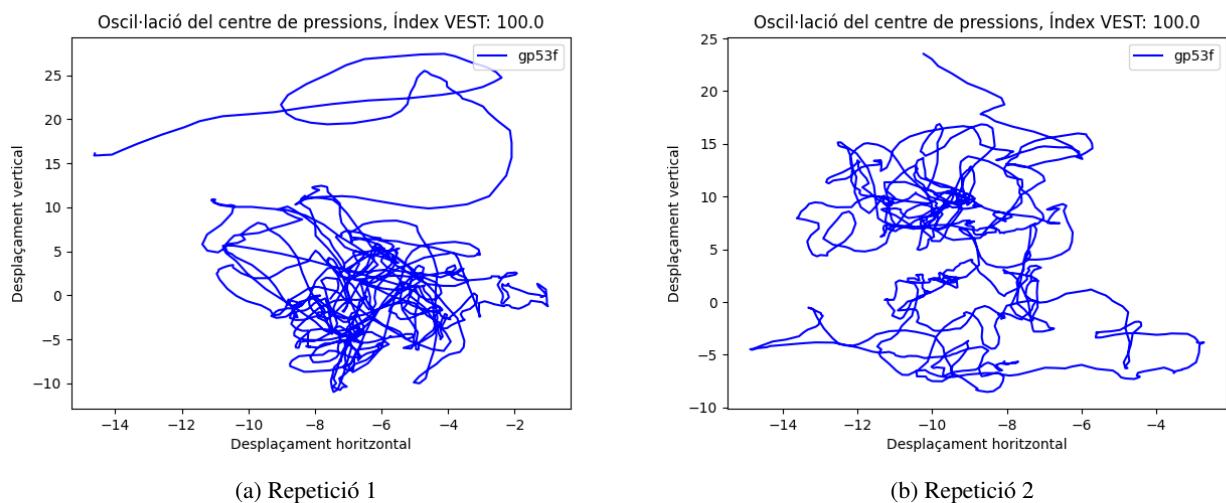
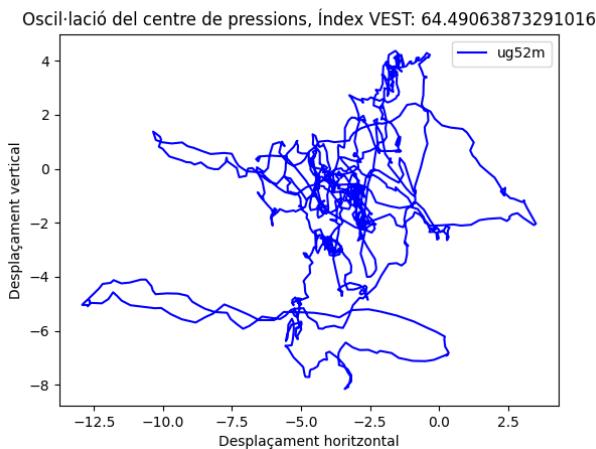
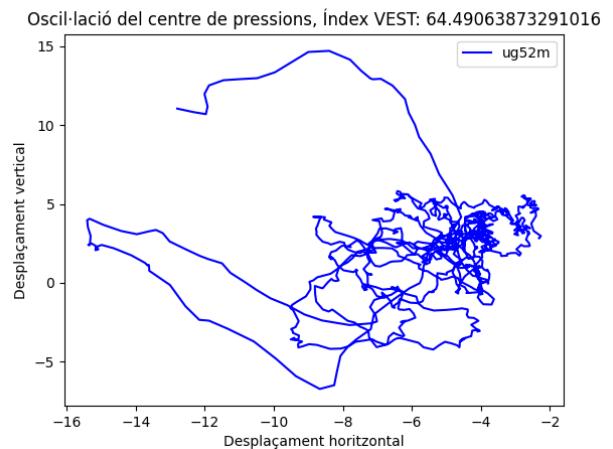


Fig. 30: Desplaçament de dues proves ROC realitzades al mateix pacient amb índex VEST 100

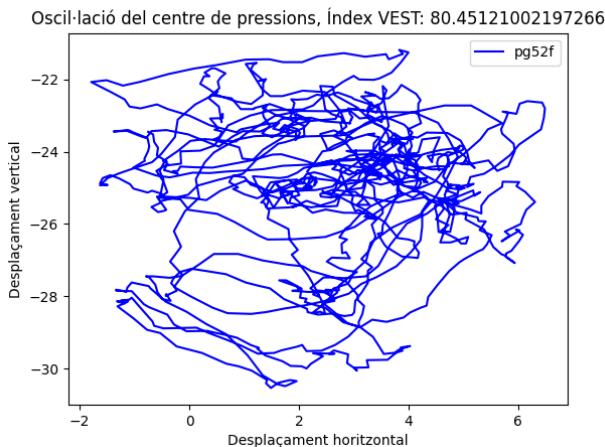


(a) Repetició 1

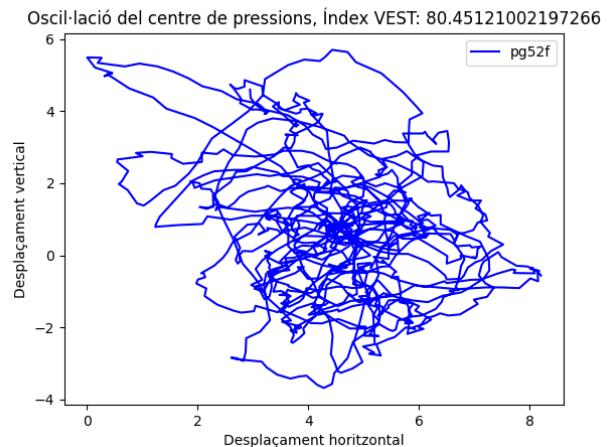


(b) Repetició 2

Fig. 31: Desplaçament de dues proves ROC realitzades al mateix pacient amb índex VEST 64.49

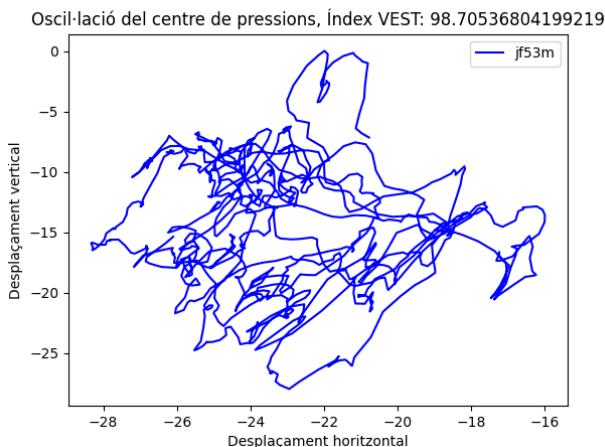


(a) Repetició 1

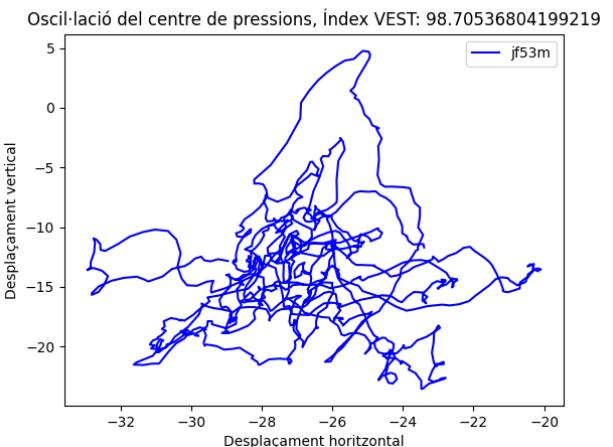


(b) Repetició 2

Fig. 32: Desplaçament de dues proves ROC realitzades al mateix pacient amb índex VEST 84.45



(a) Repetició 1



(b) Repetició 2

Fig. 33: Desplaçament de dues proves ROC realitzades al mateix pacient amb índex VEST 98.70

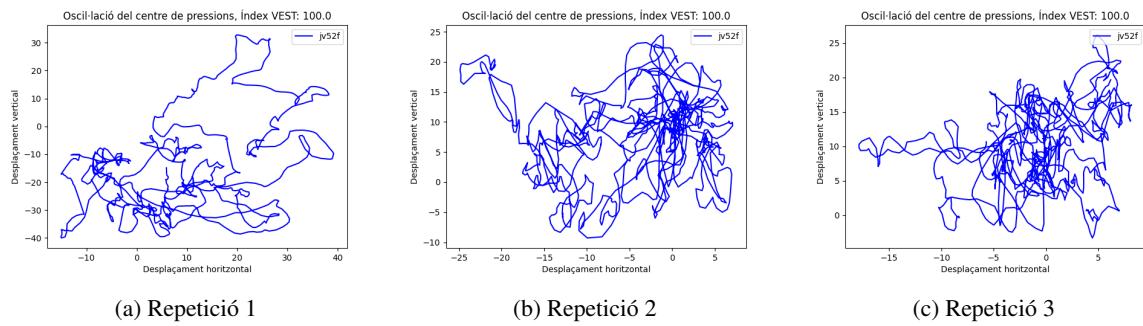


Fig. 34: Desplaçament de tres proves ROC realitzades al mateix pacient amb índex VEST 100

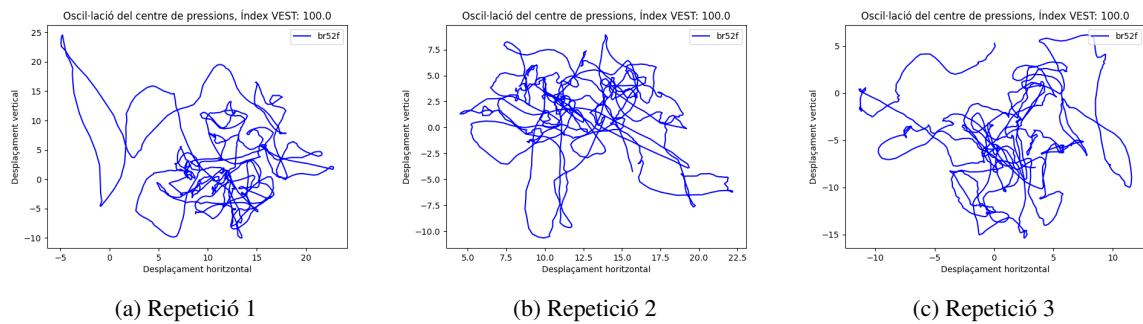


Fig. 35: Desplaçament de tres proves ROC realitzades al mateix pacient amb índex VEST 100

C.3.6 Mostres positives

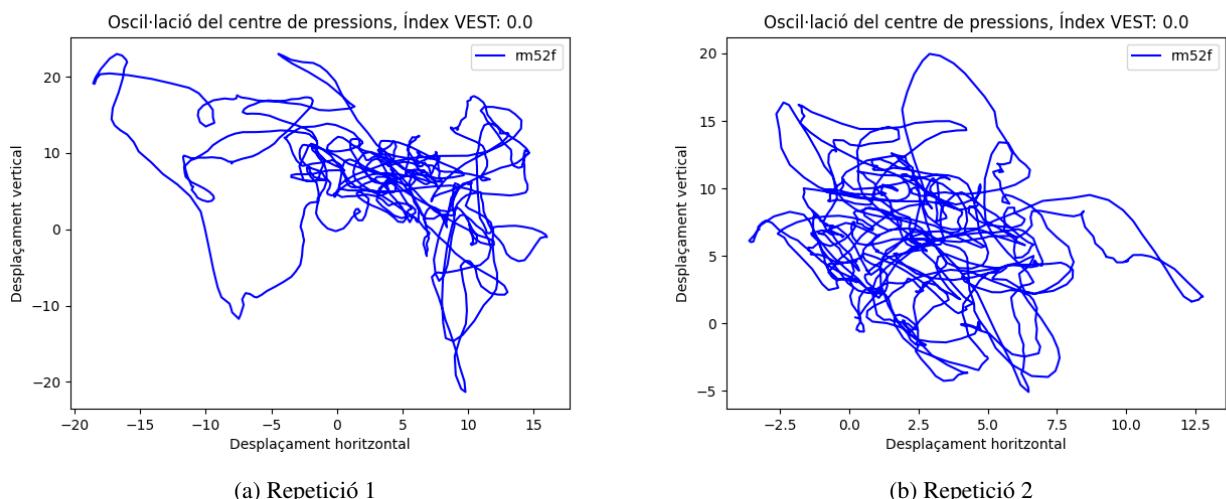


Fig. 36: Desplaçament de dues proves ROC realitzades al mateix pacient amb índex VEST 0.0

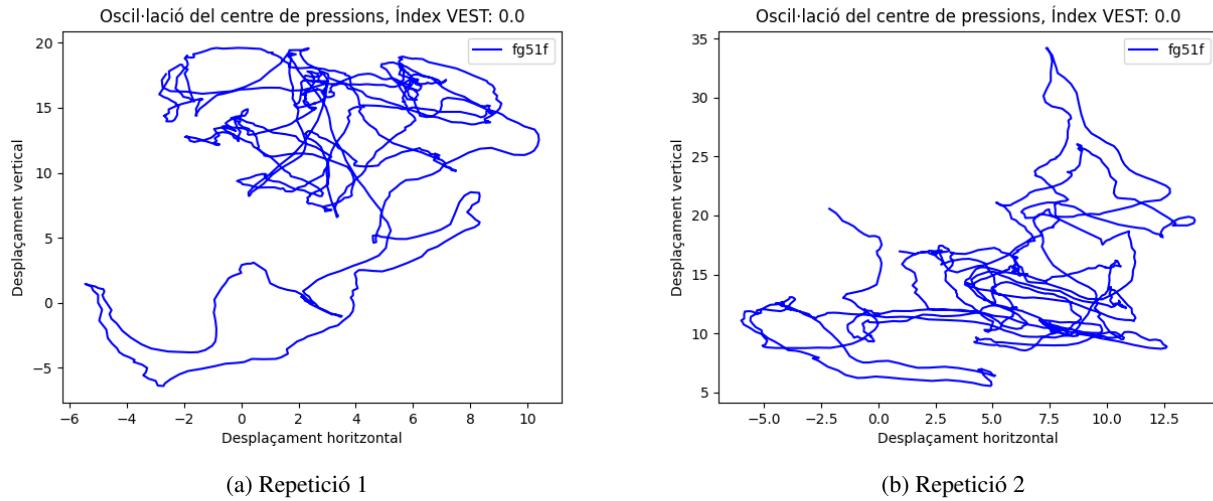


Fig. 37: Desplaçament de dues proves ROC realitzades al mateix pacient amb índex VEST 0.0

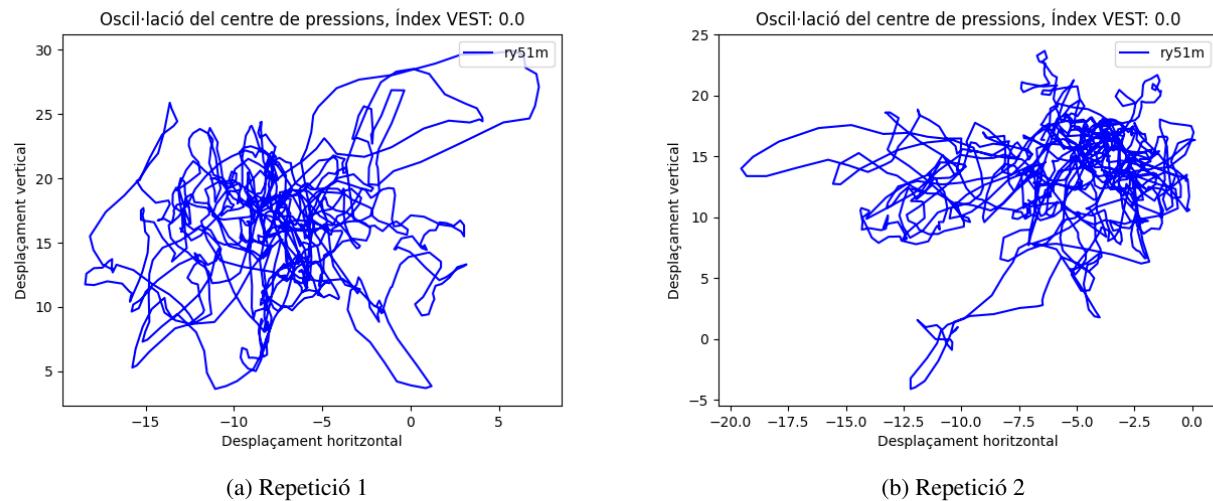


Fig. 38: Desplaçament de dues proves ROC realitzades al mateix pacient amb índex VEST 0.0

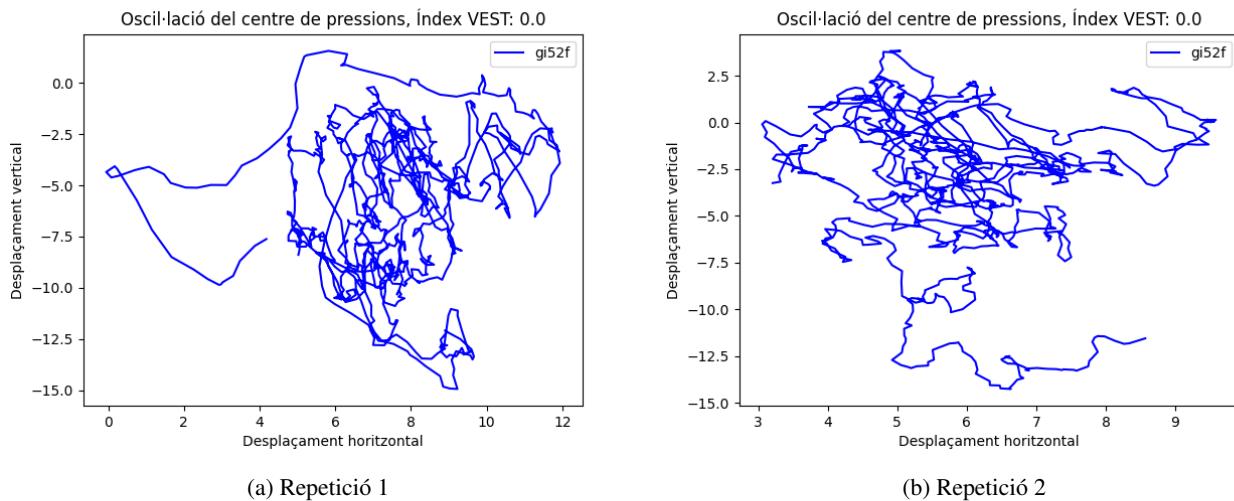
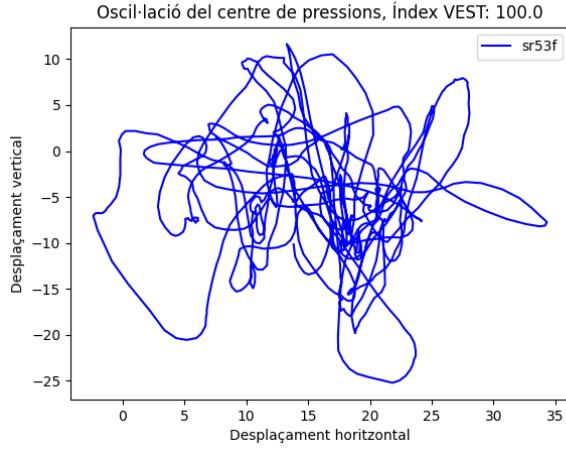


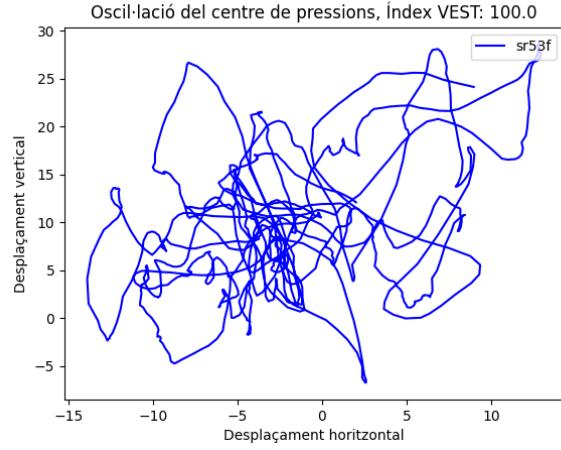
Fig. 39: Desplaçament de dues proves ROC realitzades al mateix pacient amb índex VEST 0.0

C.3.7 Gràfiques prova RGA

C.3.8 Mostres negatives

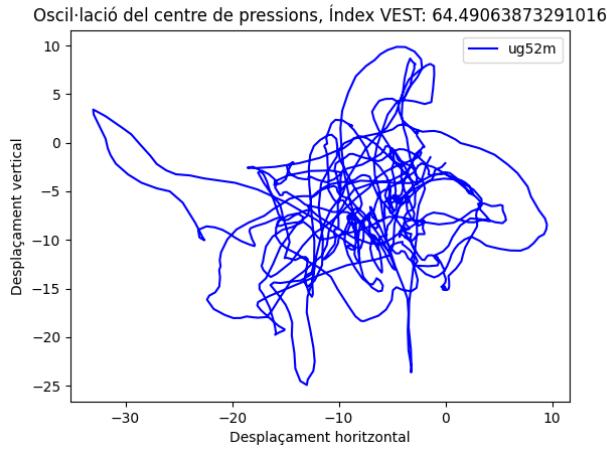


(a) Repetició 1

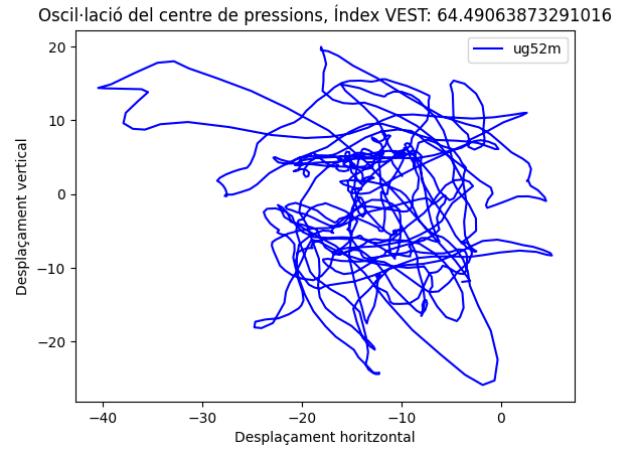


(b) Repetició 2

Fig. 40: Desplaçament de dues proves RGA realitzades al mateix pacient amb índex VEST 100

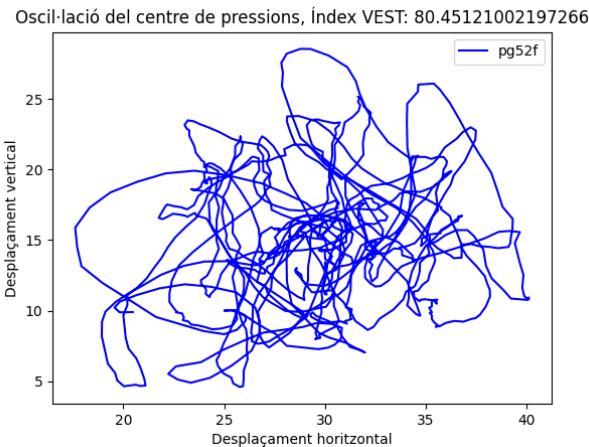


(a) Repetició 1

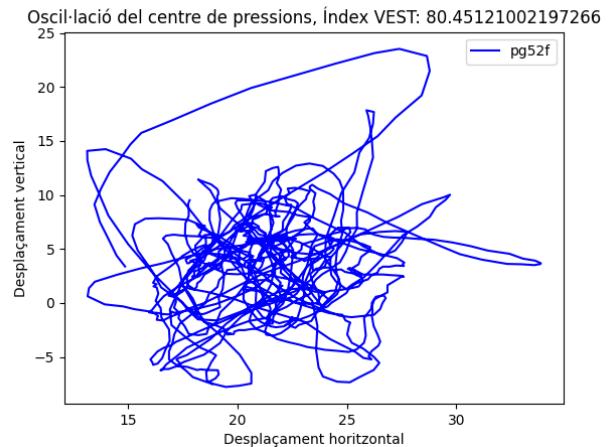


(b) Repetició 2

Fig. 41: Desplaçament de dues proves RGA realitzades al mateix pacient amb índex VEST 64.49



(a) Repetició 1



(b) Repetició 2

Fig. 42: Desplaçament de dues proves RGA realitzades al mateix pacient amb índex VEST 80.45

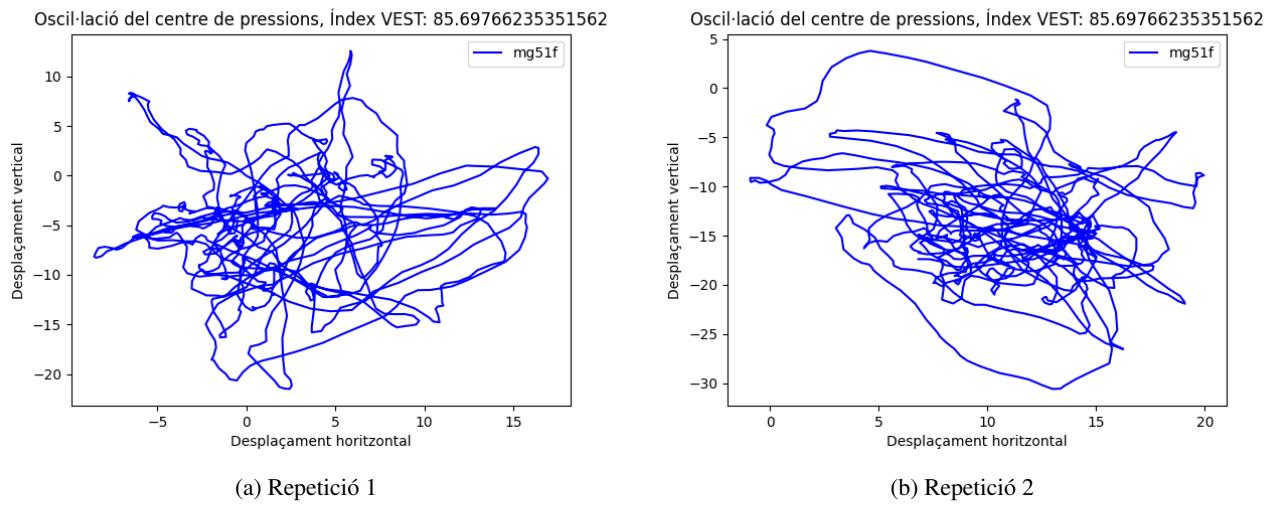


Fig. 43: Desplaçament de dues proves RGA realitzades al mateix pacient amb índex VEST 85.69

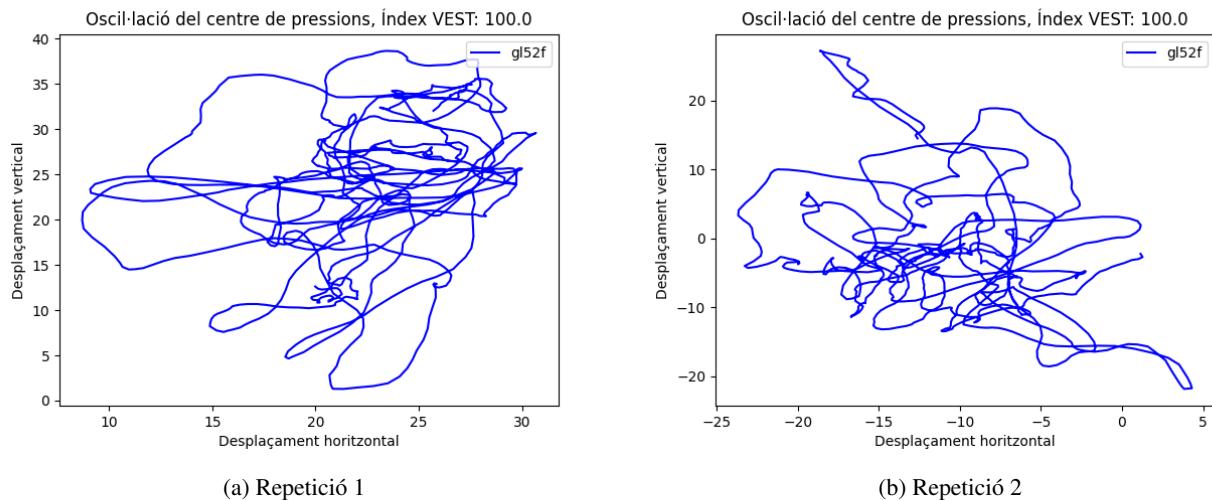


Fig. 44: Desplaçament de dues proves RGA realitzades al mateix pacient amb índex VEST 100

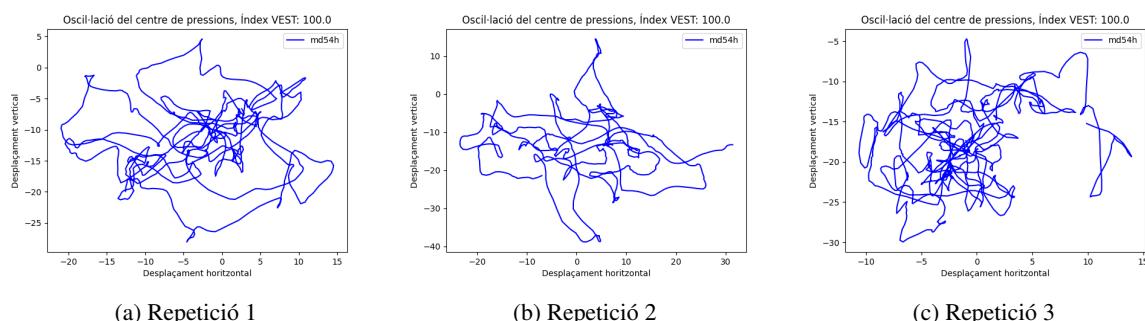
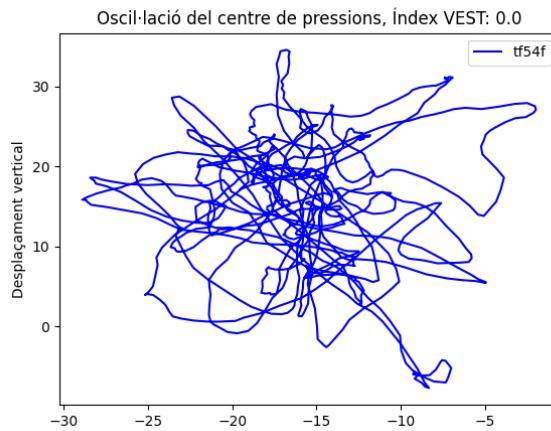
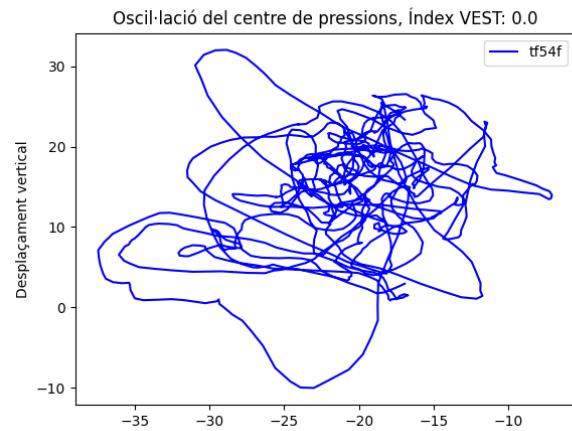


Fig. 45: Desplaçament de tres proves RGA realitzades al mateix pacient amb índex VEST 100

C.3.9 Mostres positives

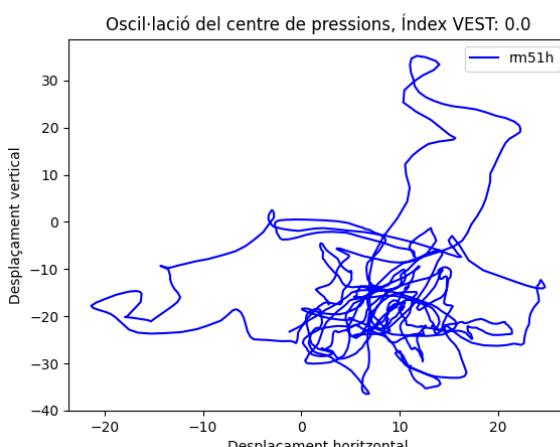


(a) Repetició 1

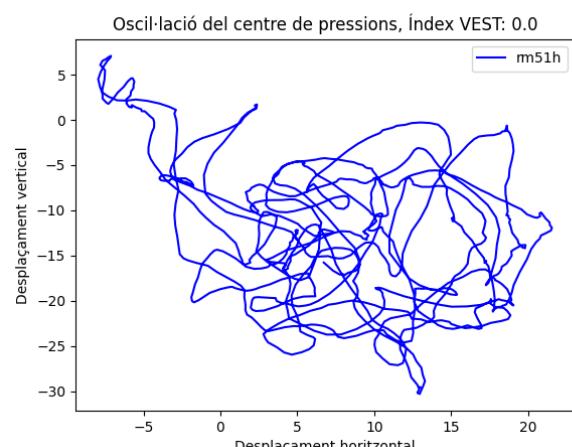


(b) Repetició 2

Fig. 46: Desplaçament de dues proves RGA realitzades al mateix pacient amb índex VEST 0.0

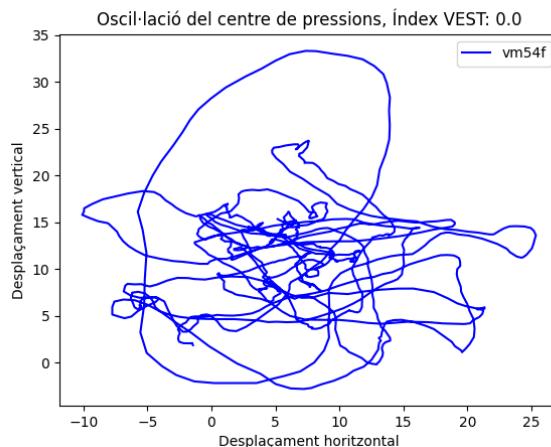


(a) Repetició 1

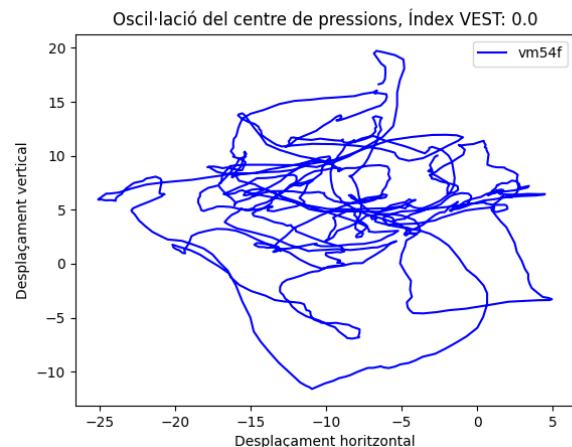


(b) Repetició 2

Fig. 47: Desplaçament de dues proves RGA realitzades al mateix pacient amb índex VEST 0.0



(a) Repetició 1



(b) Repetició 2

Fig. 48: Desplaçament de dues proves RGA realitzades al mateix pacient amb índex VEST 0.0

C.3.10 Gràfiques prova RGC

C.3.11 Mostres negatives

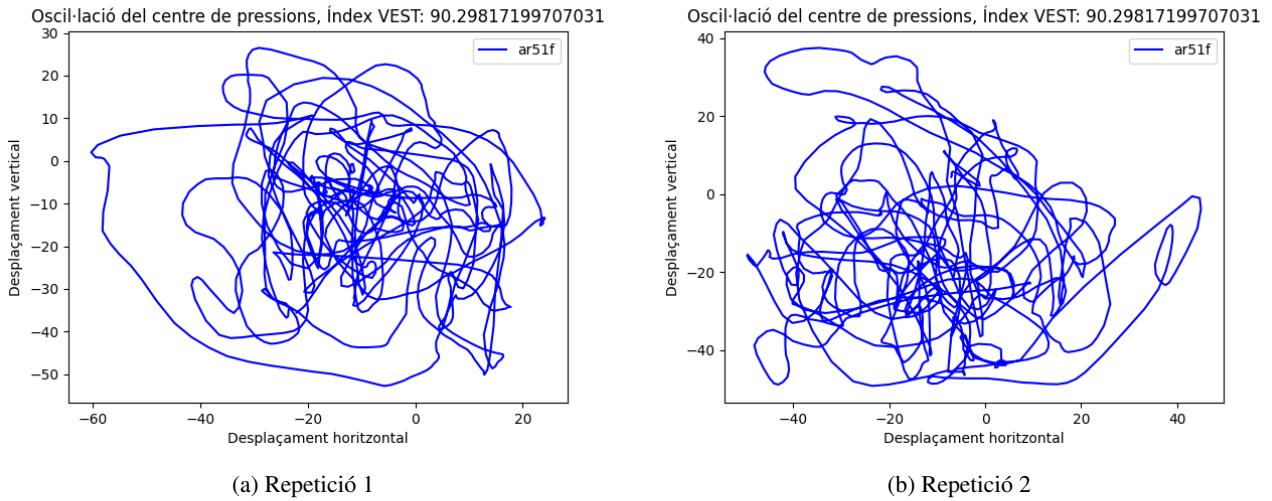


Fig. 49: Desplaçament de dues proves RGC realitzades al mateix pacient amb índex VEST 90.29

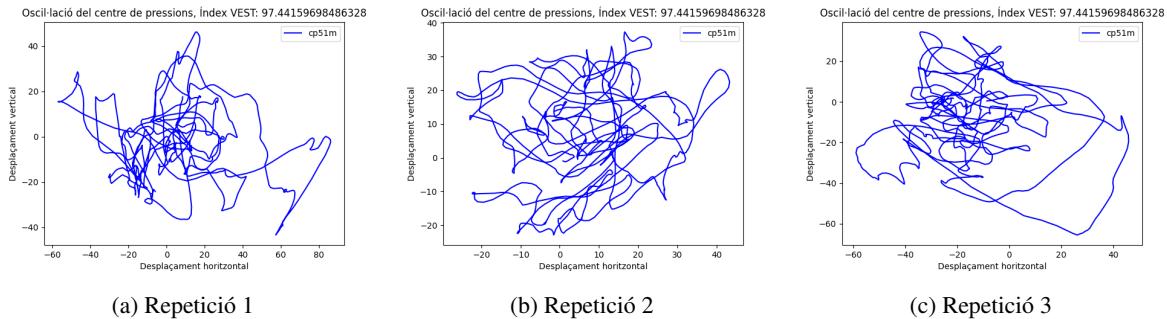


Fig. 50: Desplaçament de tres proves RGC realitzades al mateix pacient amb índex VEST 97.44

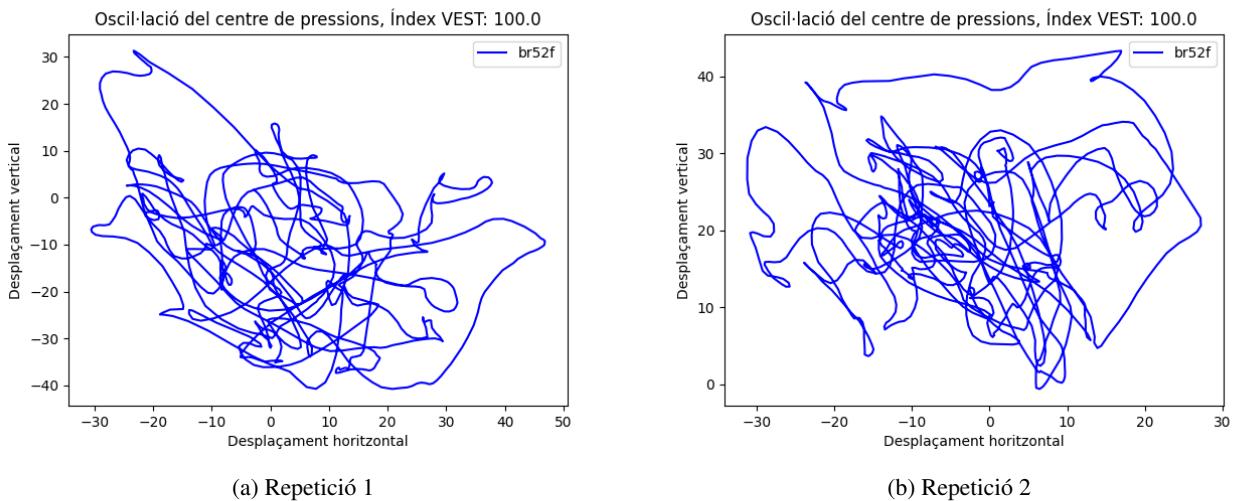
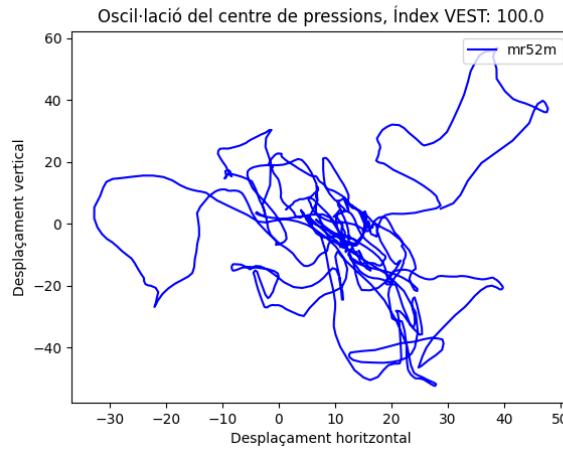
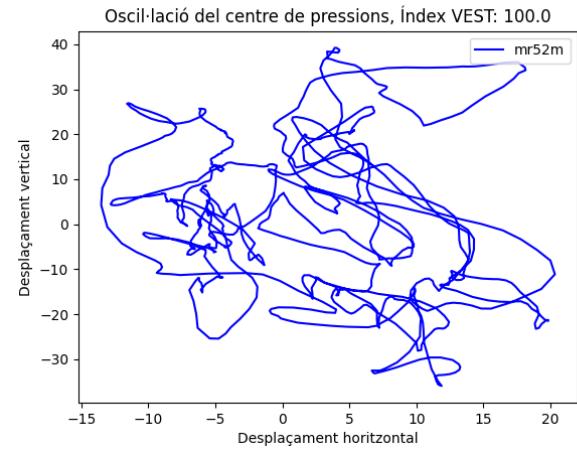


Fig. 51: Desplaçament de dues proves RGC realitzades al mateix pacient amb índex VEST 100

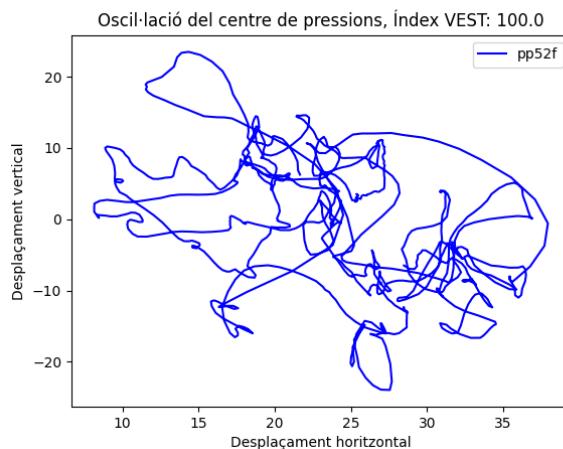


(a) Repetició 1

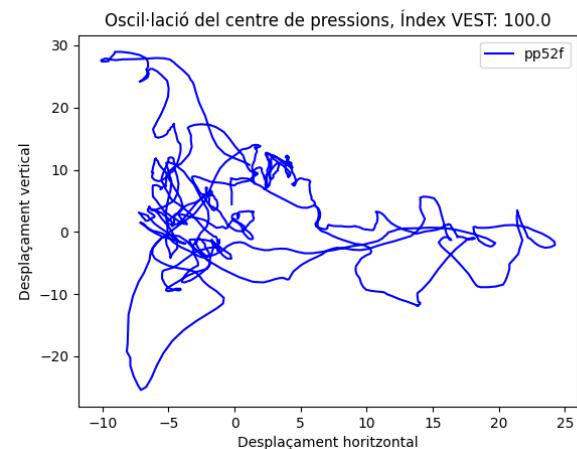


(b) Repetició 2

Fig. 52: Desplaçament de dues proves RGC realitzades al mateix pacient amb índex VEST 100



(a) Repetició 1



(b) Repetició 2

Fig. 53: Desplaçament de dues proves RGC realitzades al mateix pacient amb índex VEST 100

C.3.12 Mostres positives

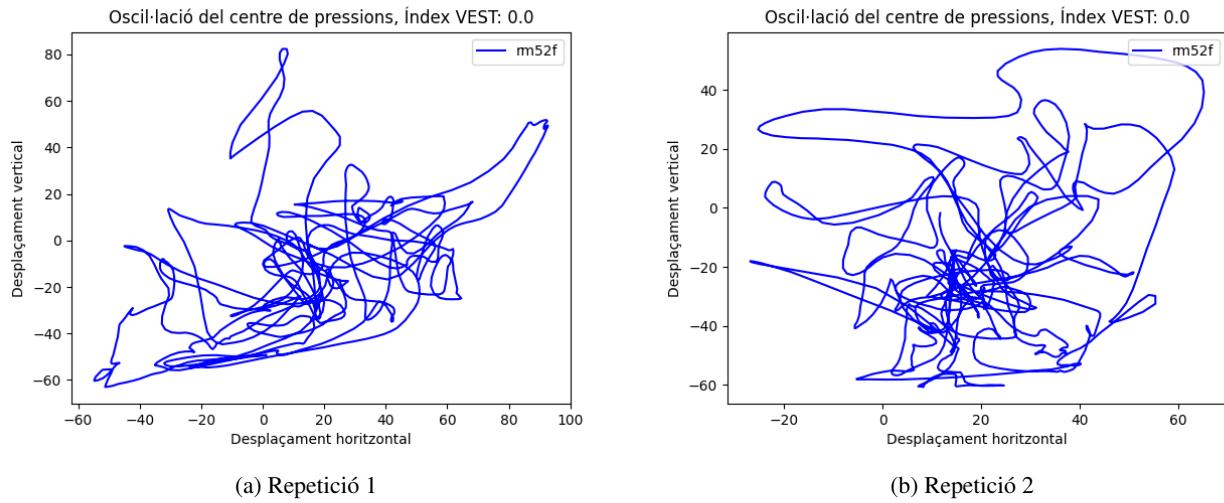


Fig. 54: Desplaçament de dues proves RGC realitzades al mateix pacient amb índex VEST 0.0

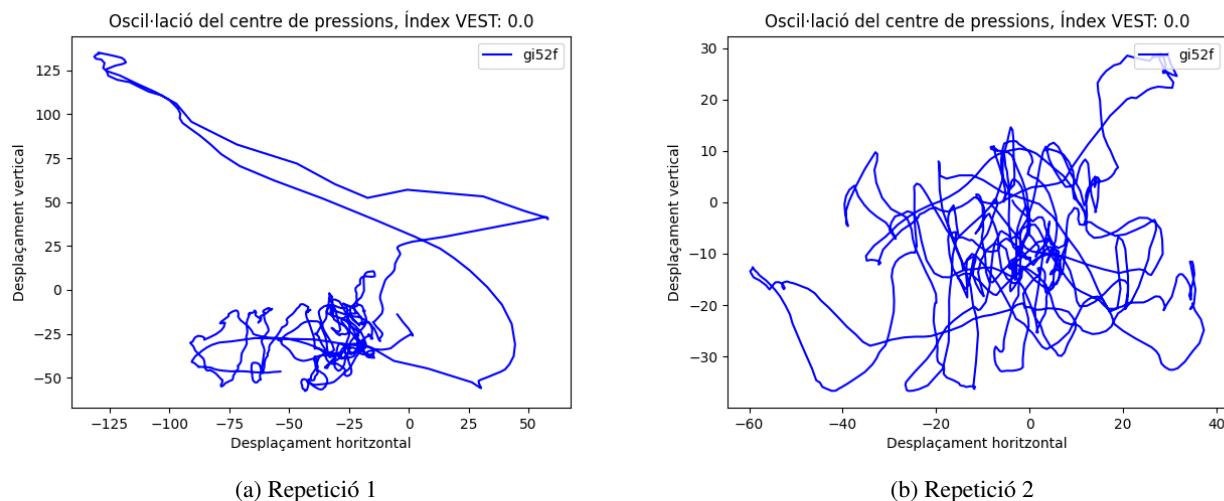


Fig. 55: Desplaçament de dues proves RGC realitzades al mateix pacient amb índex VEST 0.0

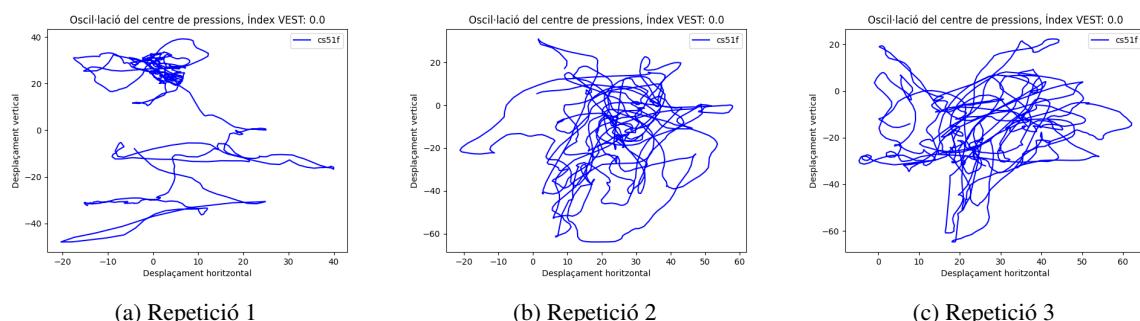


Fig. 56: Desplaçament de tres proves RGC realitzades al mateix pacient amb índex VEST 0.0

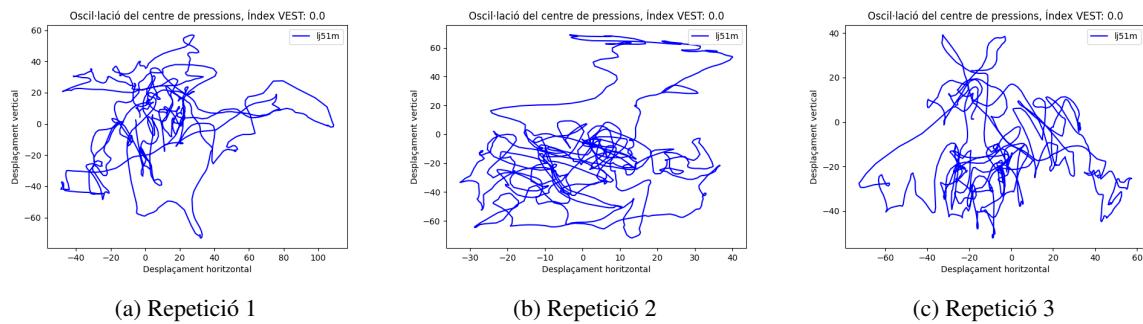


Fig. 57: Desplaçament de tres proves RGC realitzades al mateix pacient amb índex VEST 0.0

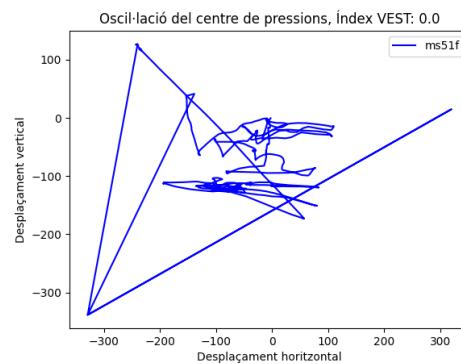


Fig. 58: Desplaçament d'una prova RGC amb índex VEST 0.0

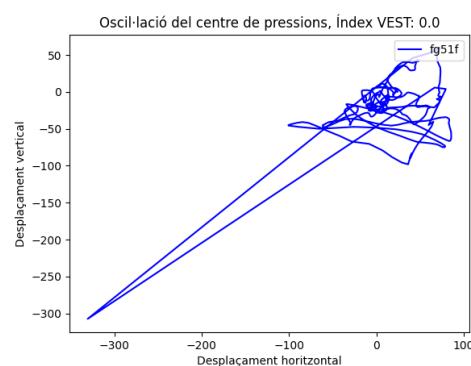


Fig. 59: Desplaçament d'una prova RGC amb índex VEST 0.0

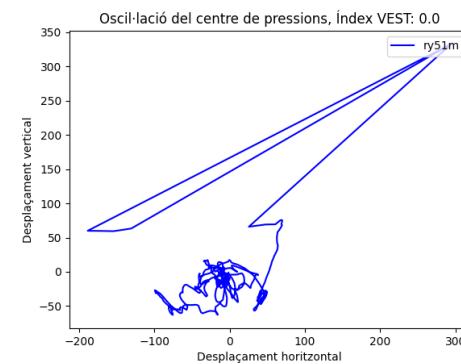


Fig. 60: Desplaçament d'una prova RGC amb índex VEST 0.0

B.4 Gràfiques de la trajectòria obtinguda amb les dades de la IMU

En aquesta secció d'apèndix es troben les gràfiques de moltes de les trajectòries obtingudes a partir de les dades de l'acceleració i el giroscopi obtingudes per el sensor MPU-9250.

B.4.1 Gràfiques prova ROA

B.4.2 Mostres negatives

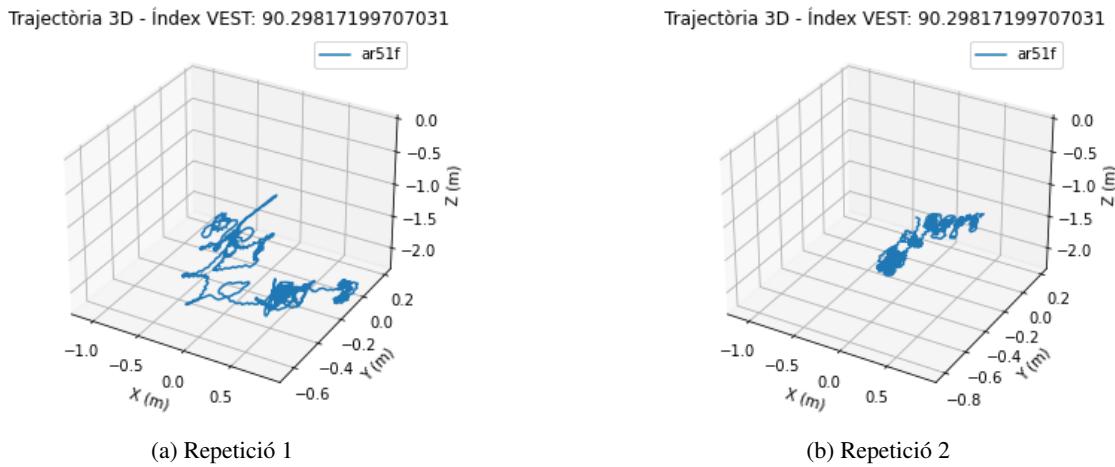


Fig. 61: Trajectòria 3D de dues proves ROA realitzades al mateix pacient amb índex VEST 90.30

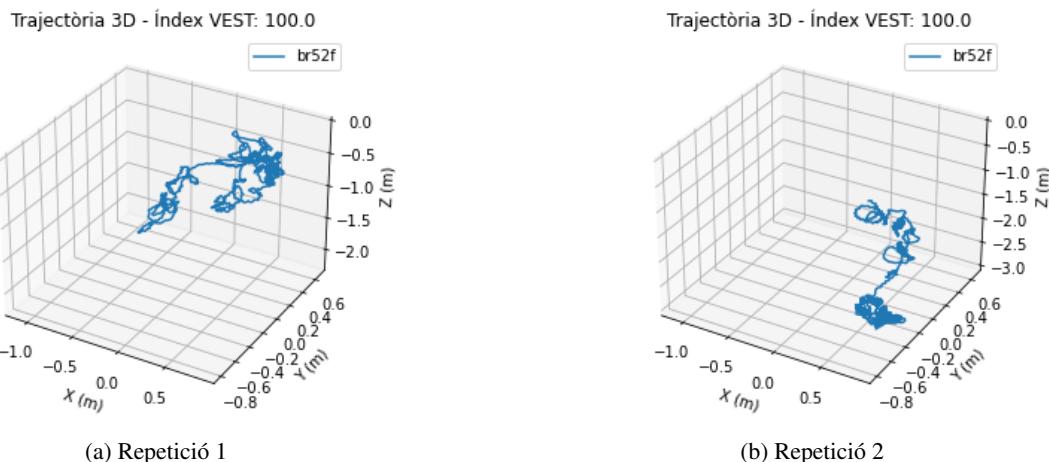


Fig. 62: Trajectòria 3D de dues proves ROA realitzades al mateix pacient amb índex VEST 100

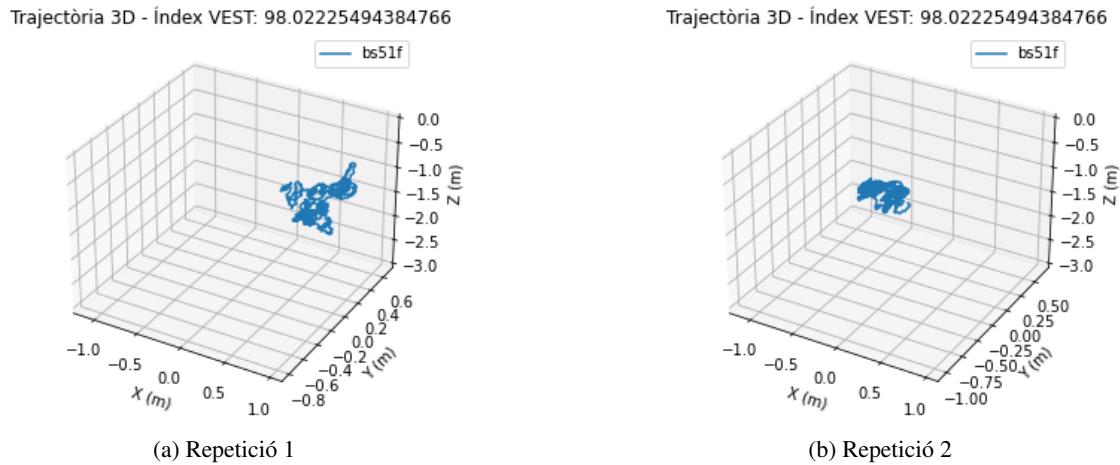


Fig. 63: Trajectòria 3D de dues proves ROA realitzades al mateix pacient amb índex VEST 98.02

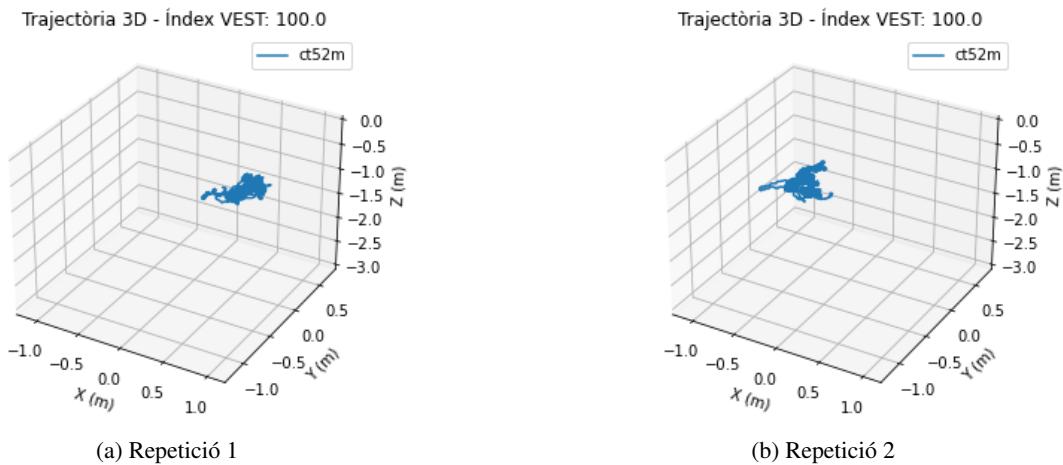


Fig. 64: Trajectòria 3D de dues proves ROA realitzades al mateix pacient amb índex VEST 100

Trajectòria 3D - Índex VEST: 97.44159698486328

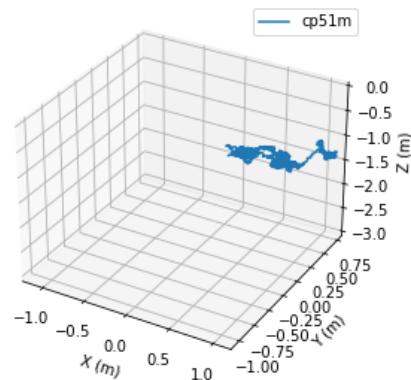


Fig. 65: Trajectòria 3D d'una prova ROA amb índex VEST 97.44

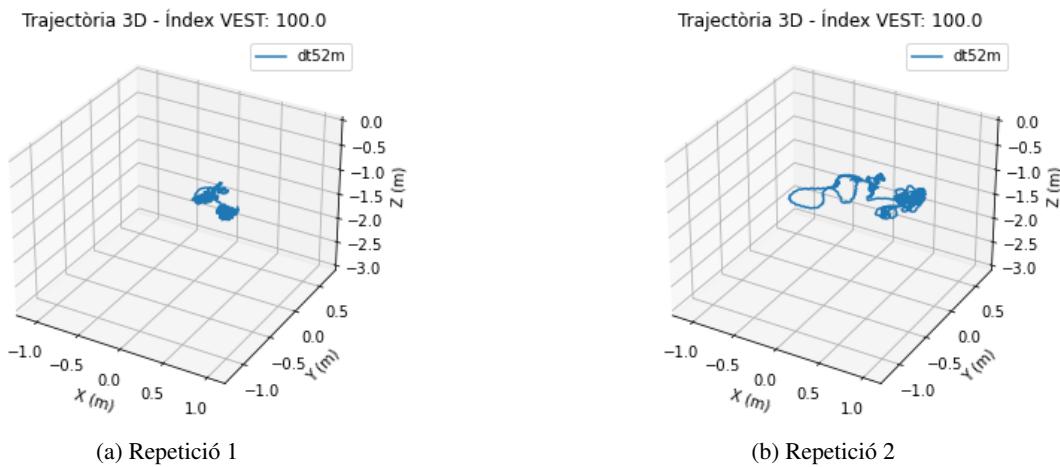


Fig. 66: Trajectòria 3D de dues proves ROA realitzades al mateix pacient amb índex VEST 100

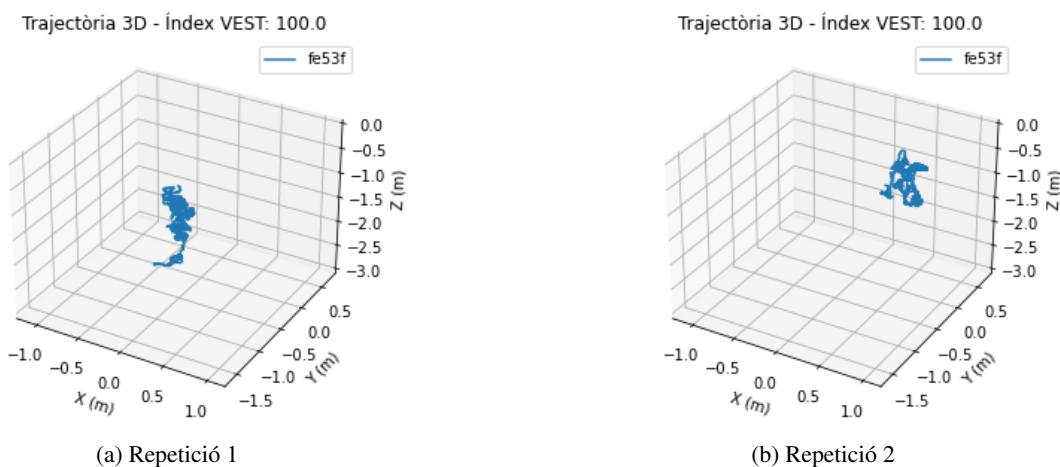


Fig. 67: Trajectòria 3D de dues proves ROA realitzades al mateix pacient amb índex VEST 100

B.4.3 Mostres positives

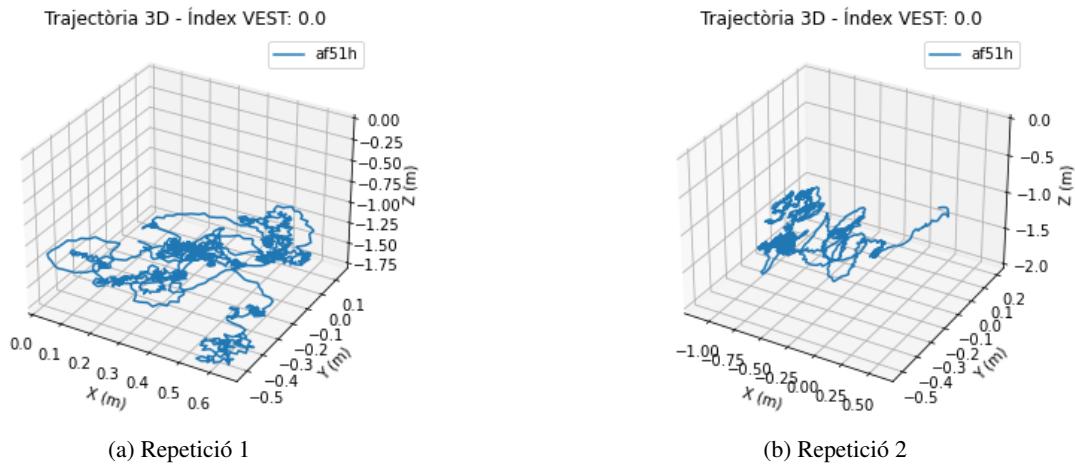


Fig. 68: Trajectòria 3D de dues proves ROA realitzades al mateix pacient amb índex VEST 0.0

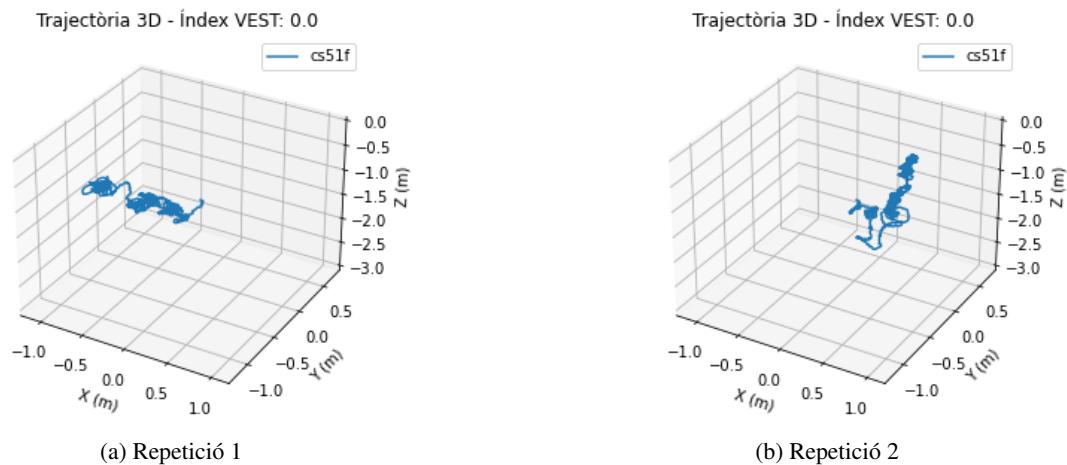


Fig. 69: Trajectòria 3D de dues proves ROA realitzades al mateix pacient amb índex VEST 0.0

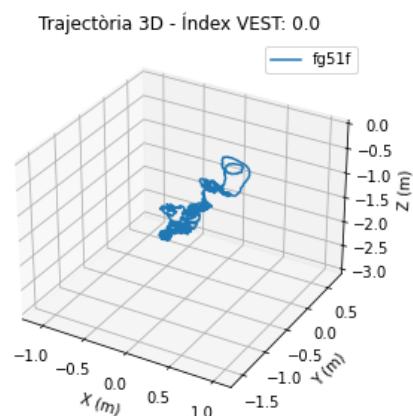


Fig. 70: Trajectòria 3D d'una prova ROA amb índex VEST 0.0

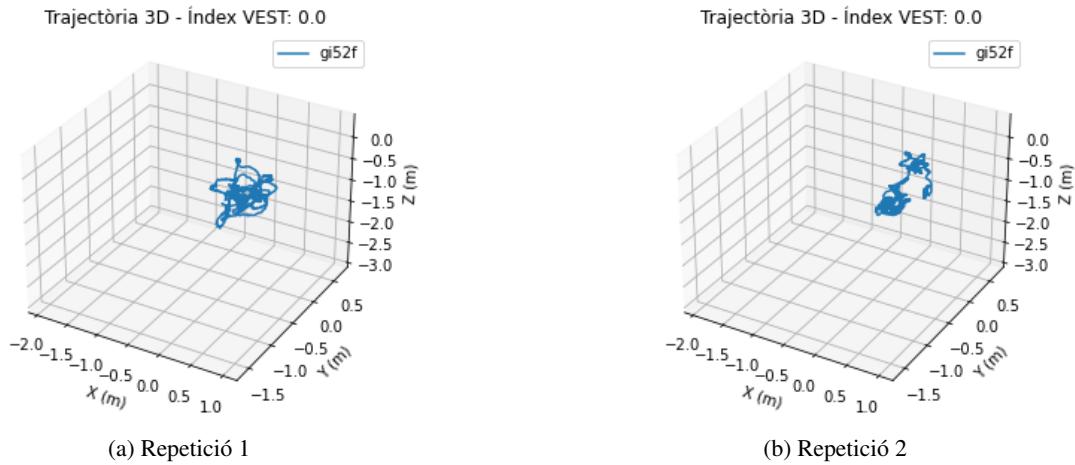


Fig. 71: Trajectòria 3D de dues proves ROA realitzades al mateix pacient amb índex VEST 0.0

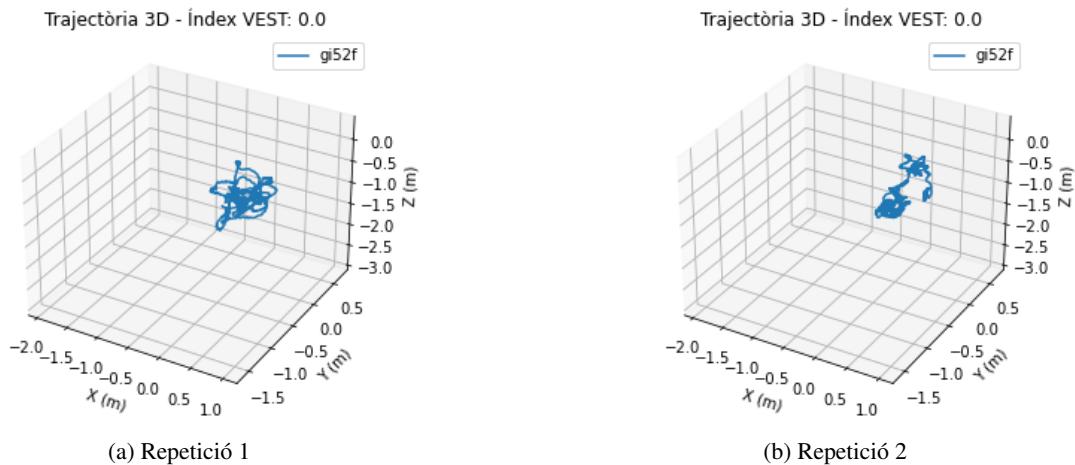


Fig. 72: Trajectòria 3D de dues proves ROA realitzades al mateix pacient amb índex VEST 0.0

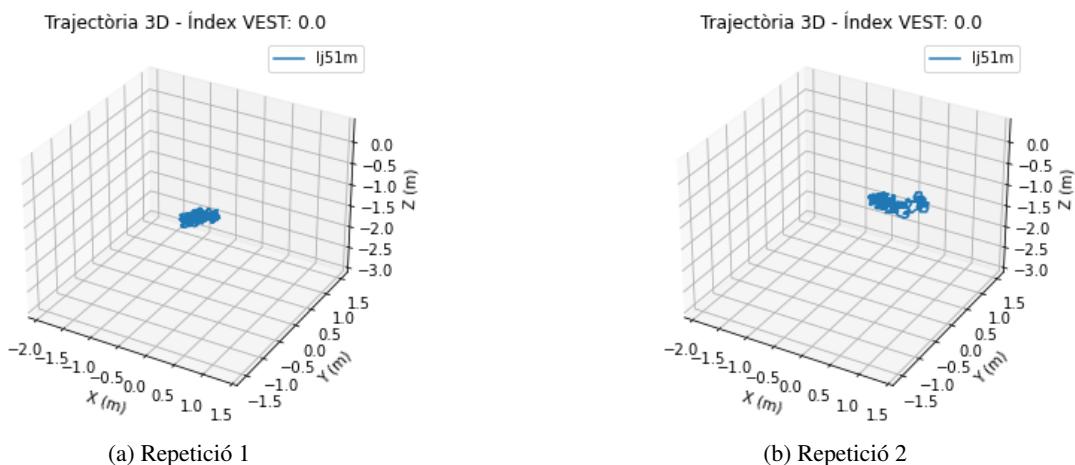


Fig. 73: Trajectòria 3D de dues proves ROA realitzades al mateix pacient amb índex VEST 0.0

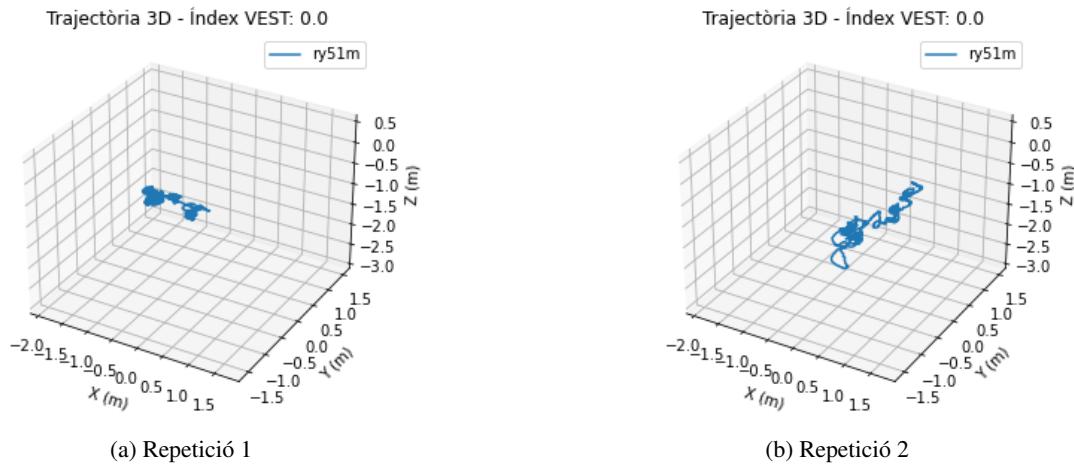


Fig. 74: Trajectòria 3D de dues proves ROA realitzades al mateix pacient amb índex VEST 0.0

B.4.4 Gràfiques prova ROC

B.4.5 Mostres negatives

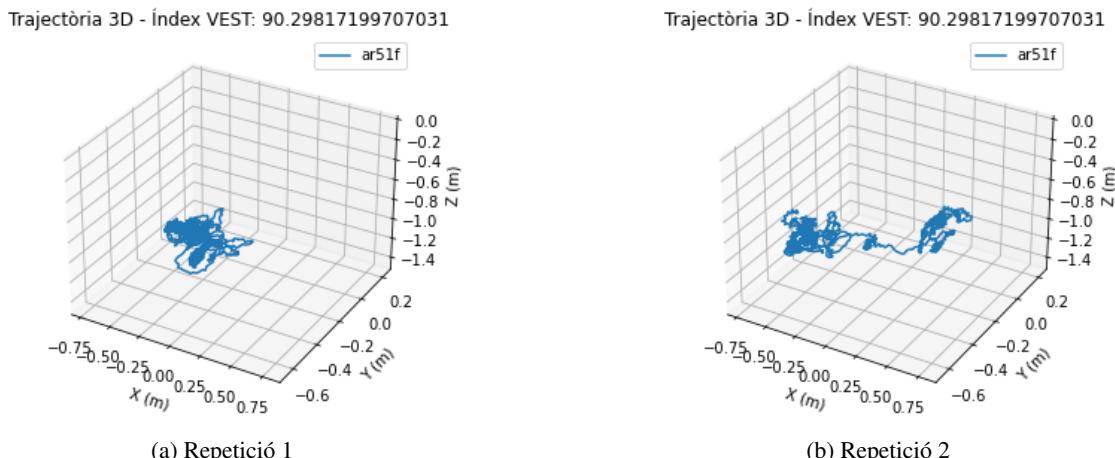


Fig. 75: Trajectòria 3D de dues proves ROC realitzades al mateix pacient amb índex VEST 90.30

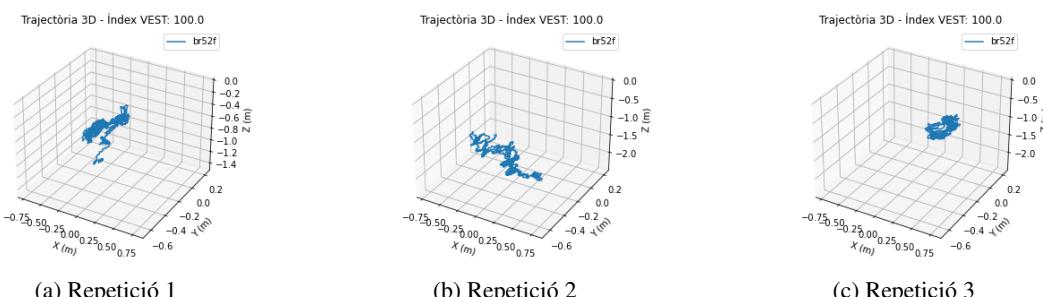


Fig. 76: Trajectòria 3D de tres proves ROC realitzades al mateix pacient amb índex VEST 100

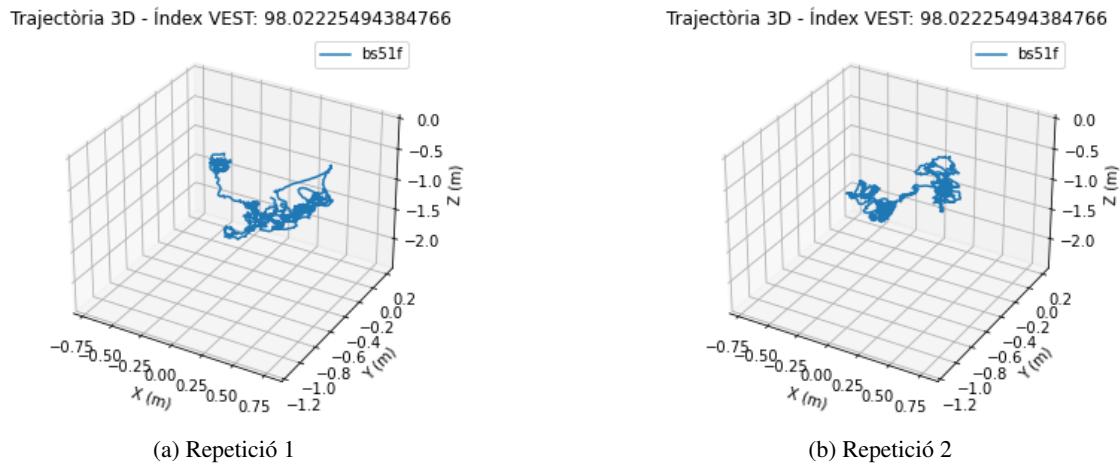
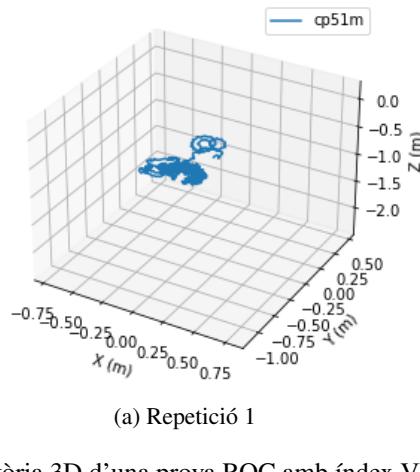


Fig. 77: Trajectòria 3D de tres proves ROC realitzades al mateix pacient amb índex VEST 98.02

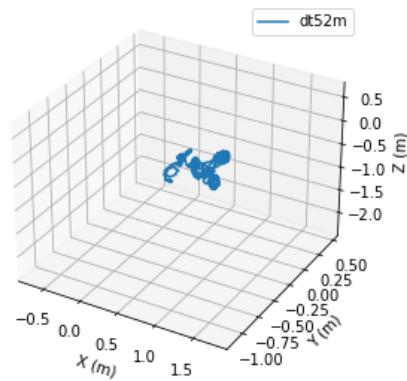
Trajectòria 3D - Índex VEST: 97.44159698486328



(a) Repetició 1

Fig. 78: Trajectòria 3D d'una prova ROC amb índex VEST 97.44

Trajectòria 3D - Índex VEST: 100.0



(a) Repetició 1

Fig. 79: Trajectòria 3D d'una prova ROC amb índex VEST 100

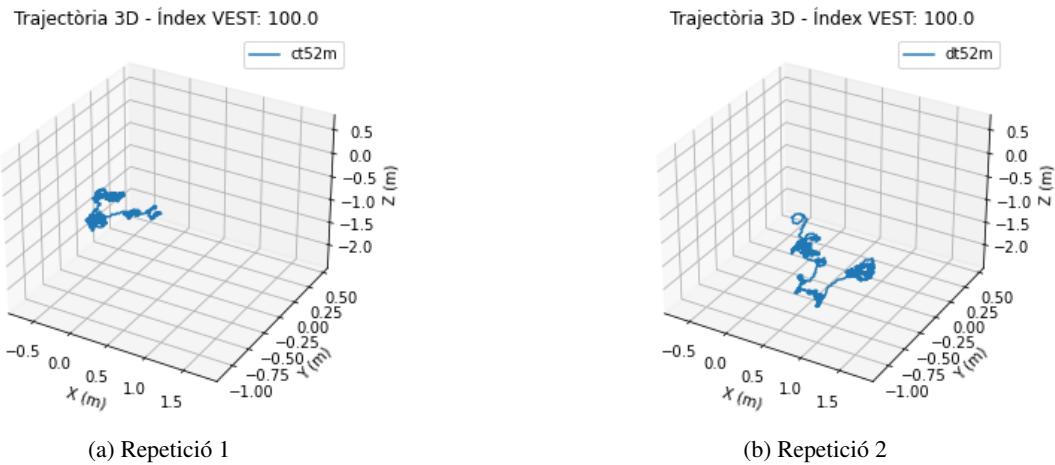


Fig. 80: Trajectòria 3D de dues proves ROC realitzades al mateix pacient amb índex VEST 100

B.4.6 Mostres positives

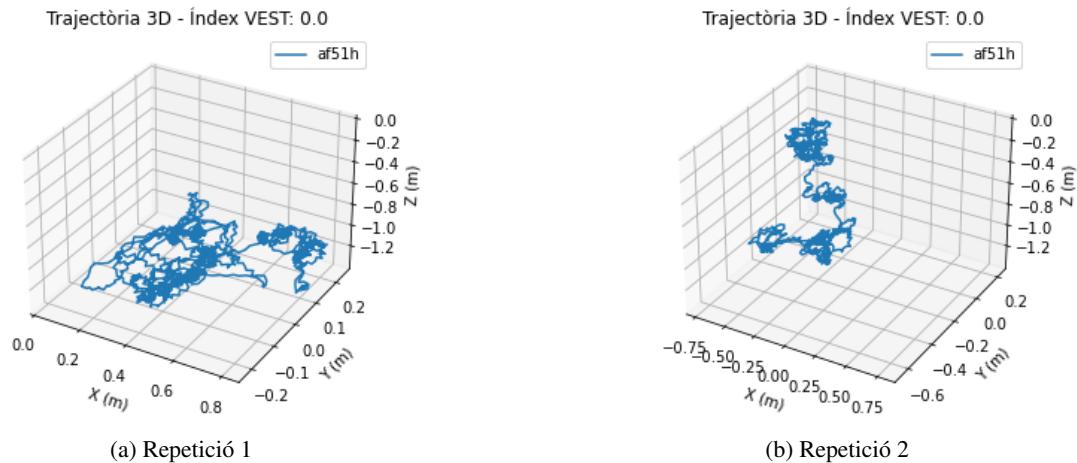


Fig. 81: Trajectòria 3D de dues proves ROC realitzades al mateix pacient amb índex VEST 0.0

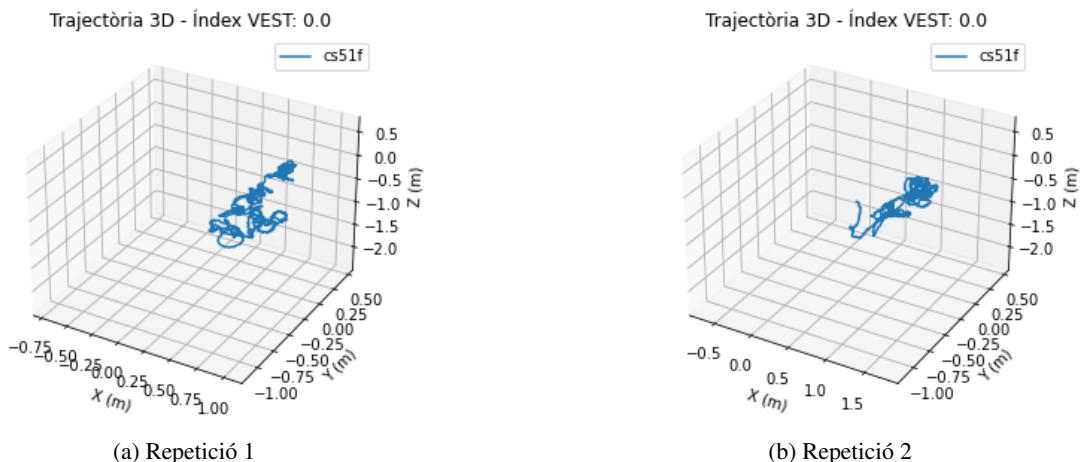


Fig. 82: Trajectòria 3D de dues proves ROC realitzades al mateix pacient amb índex VEST 0.0

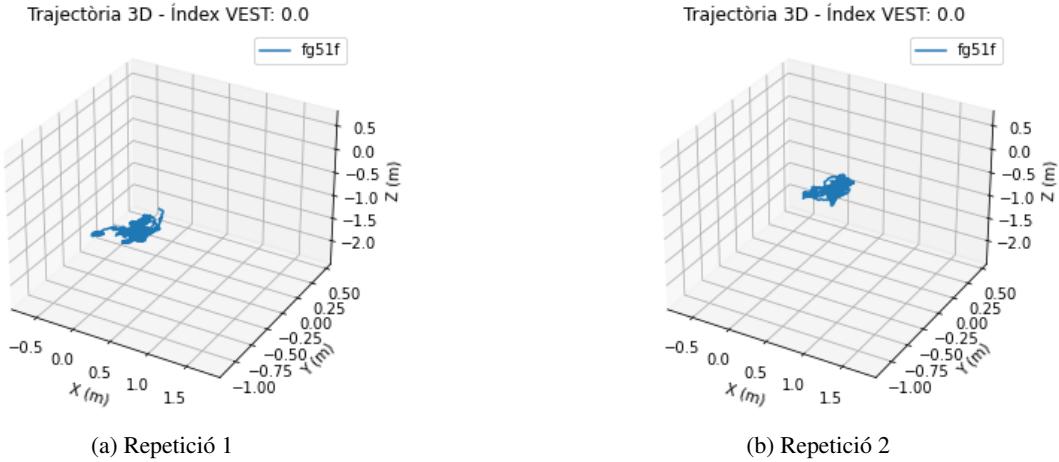


Fig. 83: Trajectòria 3D de dues proves ROC realitzades al mateix pacient amb índex VEST 0.0

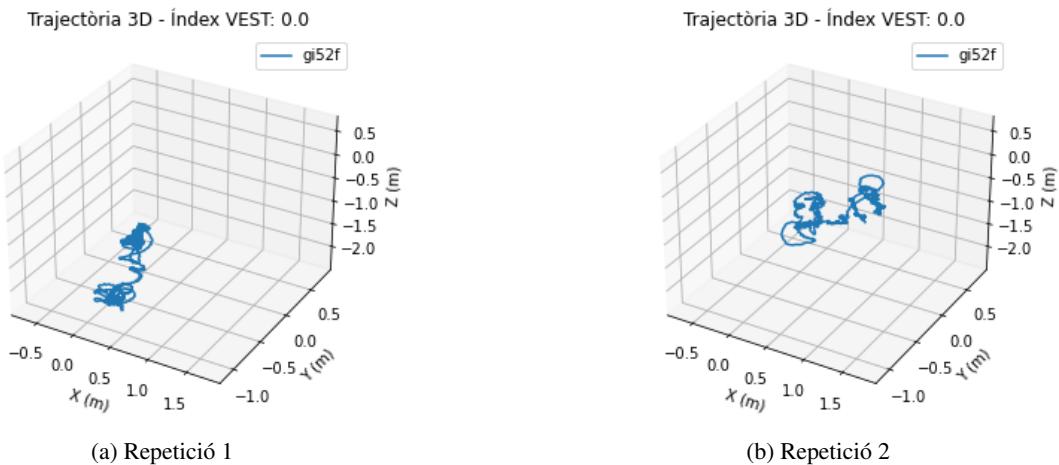


Fig. 84: Trajectòria 3D de dues proves ROC realitzades al mateix pacient amb índex VEST 0.0

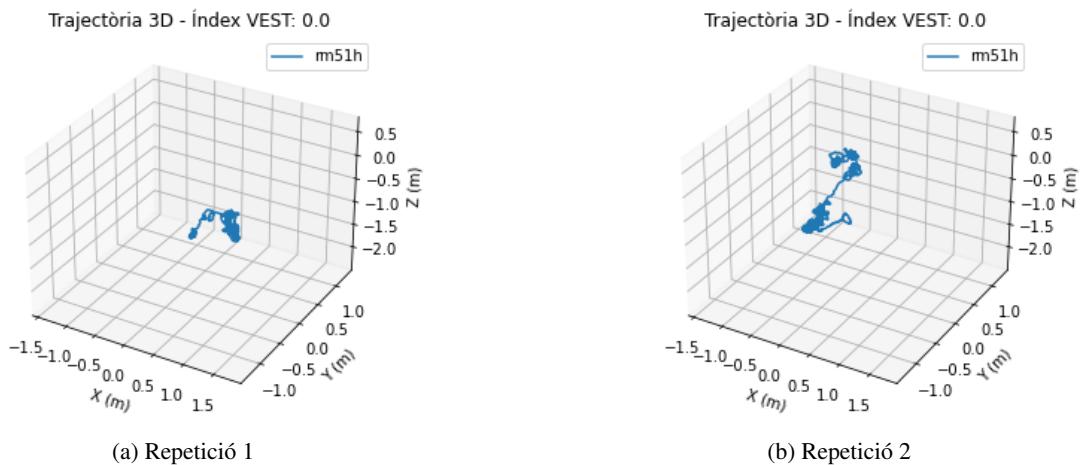


Fig. 85: Trajectòria 3D de dues proves ROC realitzades al mateix pacient amb índex VEST 0.0

B.4.7 Gràfiques prova RGA

B.4.8 Mostres negatives

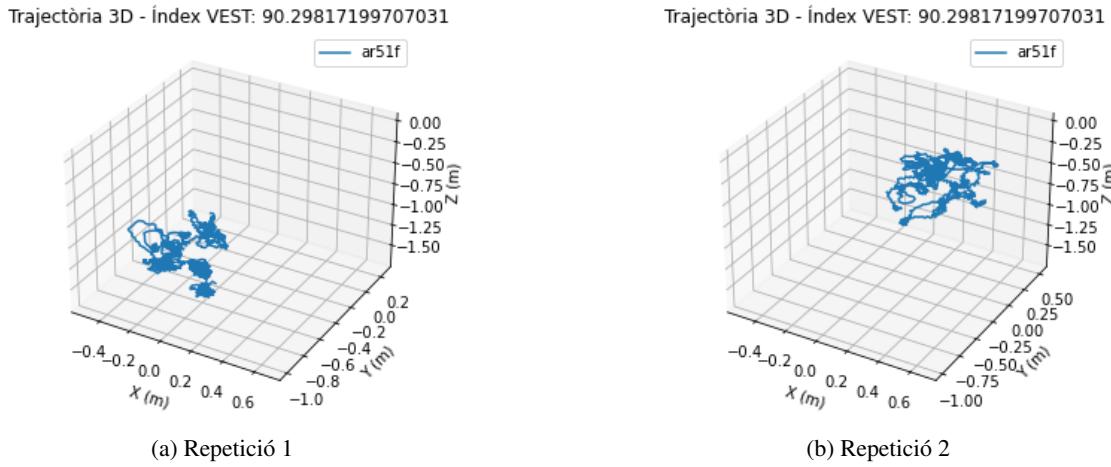


Fig. 86: Trajectòria 3D de dues proves RGA realitzades al mateix pacient amb índex VEST 90.30

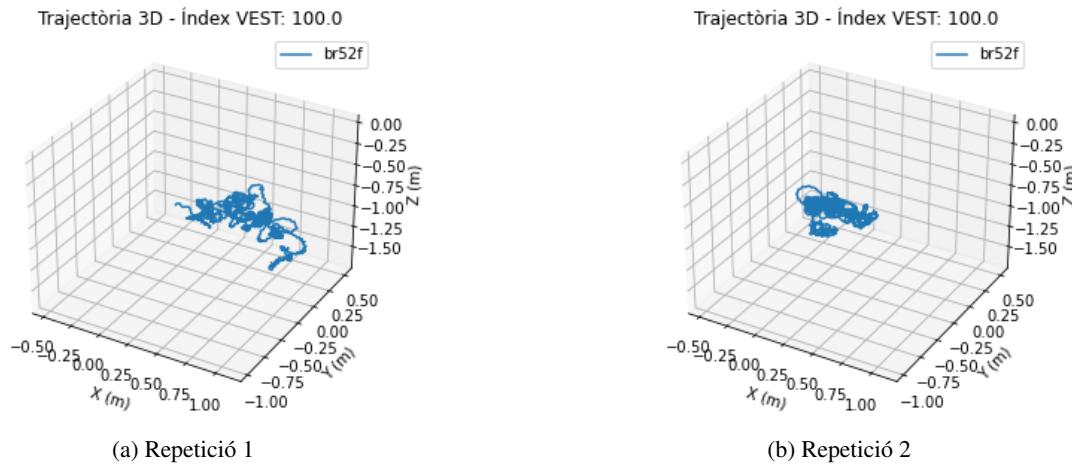


Fig. 87: Trajectòria 3D de dues proves RGA realitzades al mateix pacient amb índex VEST 100

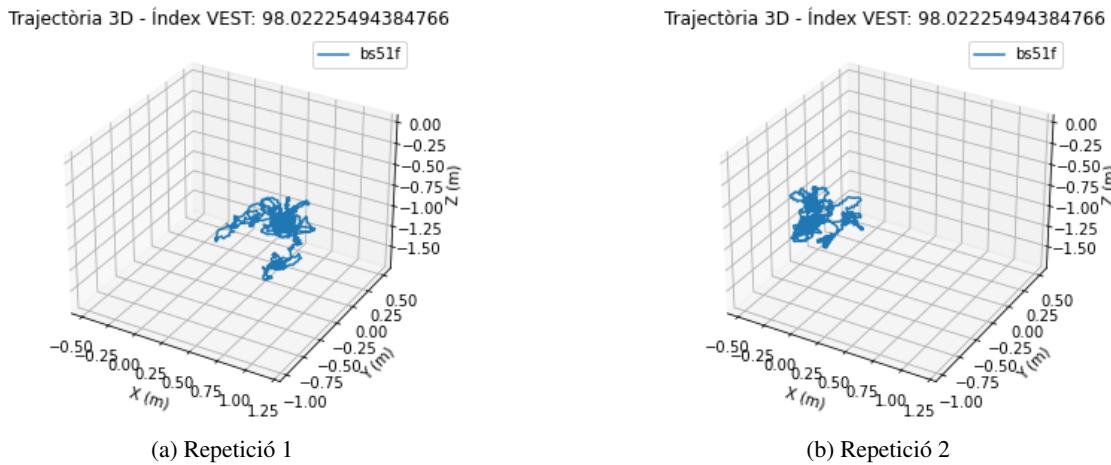


Fig. 88: Trajectòria 3D de dues proves RGA realitzades al mateix pacient amb índex VEST 98.02

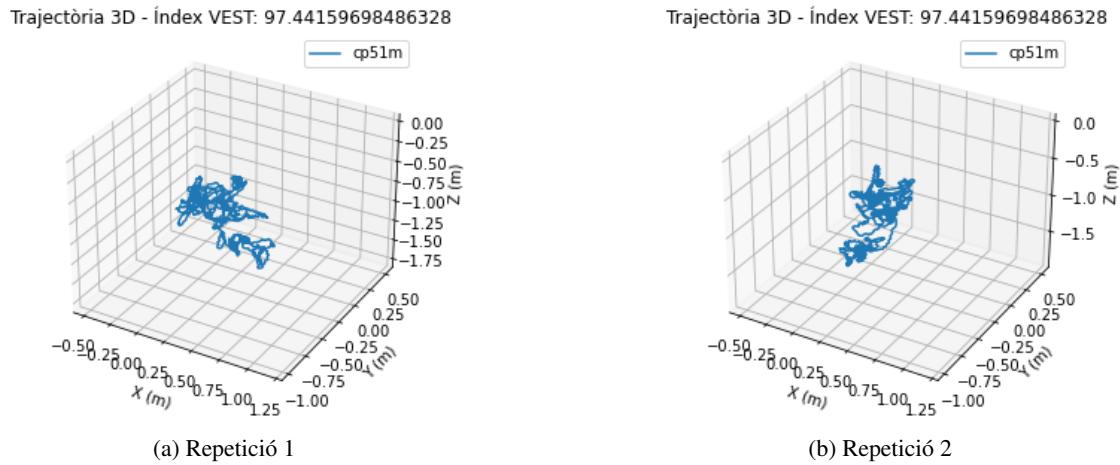


Fig. 89: Trajectòria 3D de dues proves RGA realitzades al mateix pacient amb índex VEST 97.44

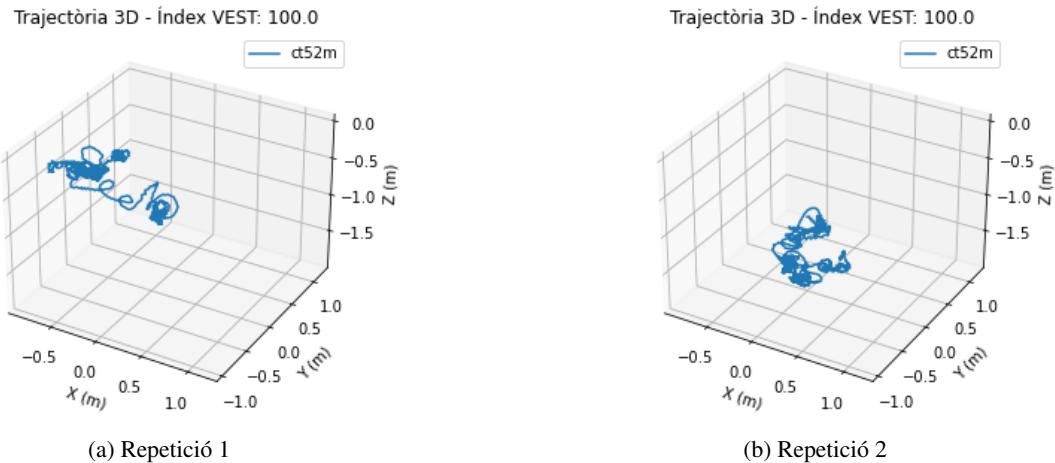


Fig. 90: Trajetòria 3D de dues proves RGA realitzades al mateix pacient amb índex VEST 100

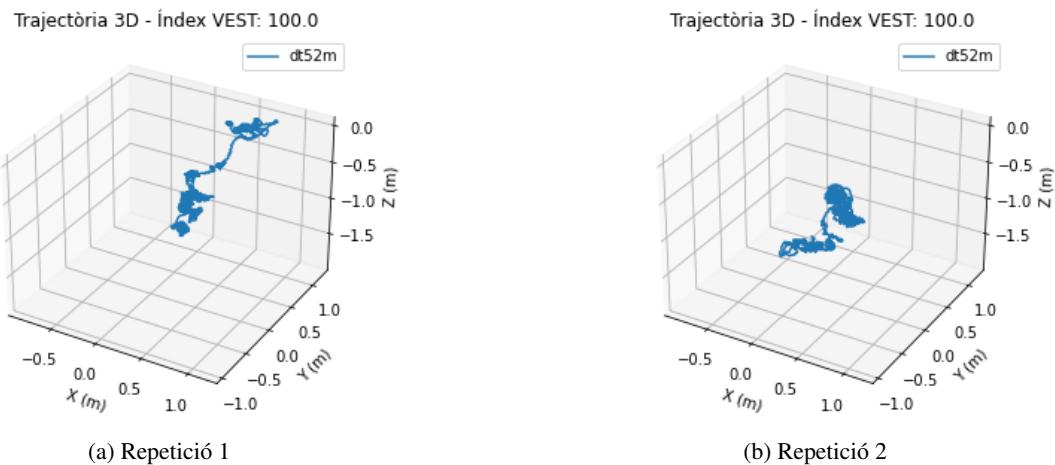


Fig. 91: Trajetòria 3D de dues proves RGA realitzades al mateix pacient amb índex VEST 100

B.4.9 Mostres positives

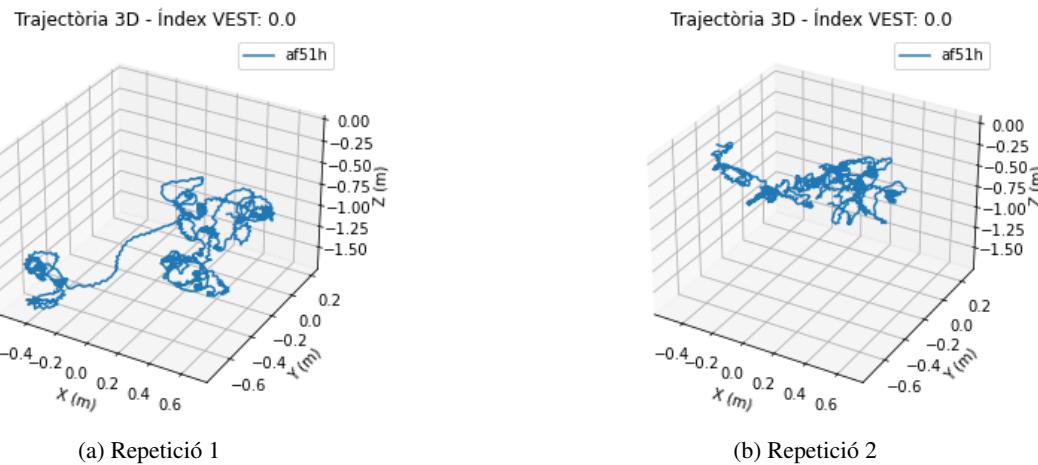


Fig. 92: Trajectòria 3D de dues proves RGA realitzades al mateix pacient amb índex VEST 0.0

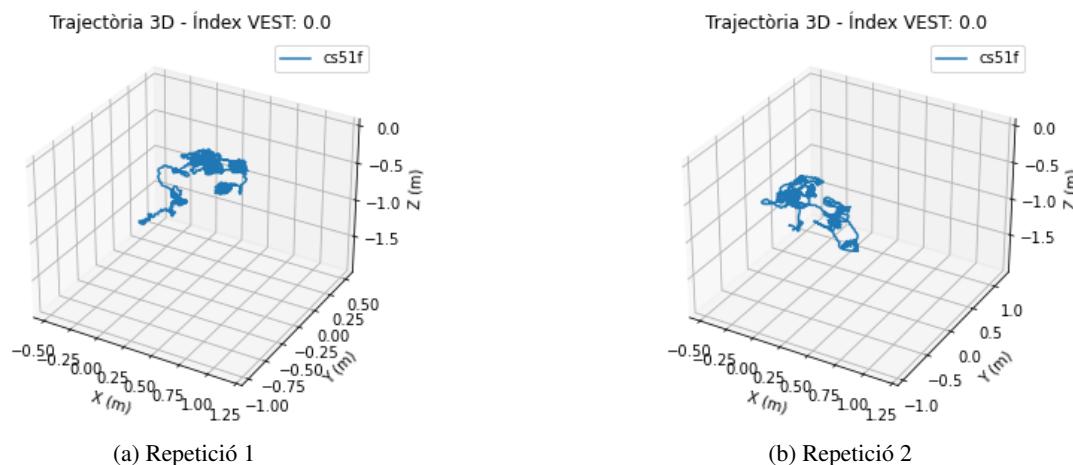


Fig. 93: Trajectòria 3D de dues proves RGA realitzades al mateix pacient amb índex VEST 0.0

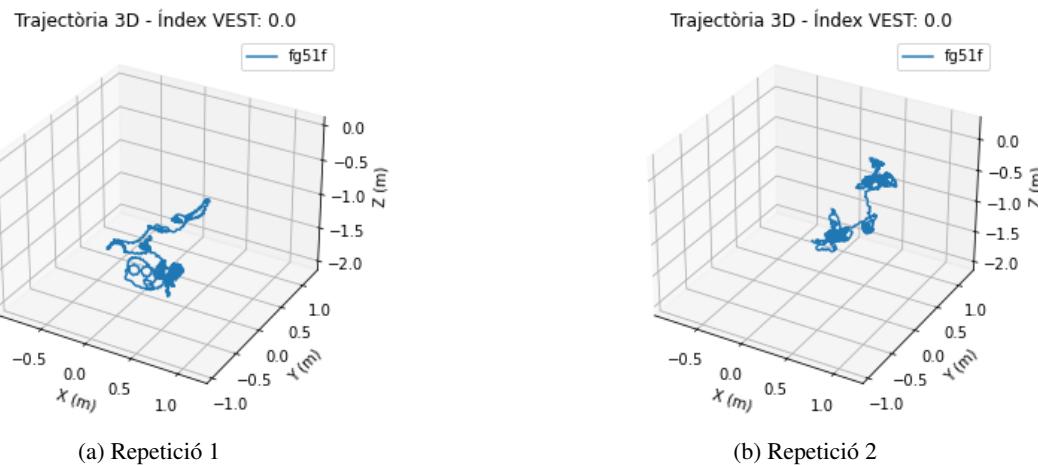


Fig. 94: Trajectòria 3D de dues proves RGA realitzades al mateix pacient amb índex VEST 0.0

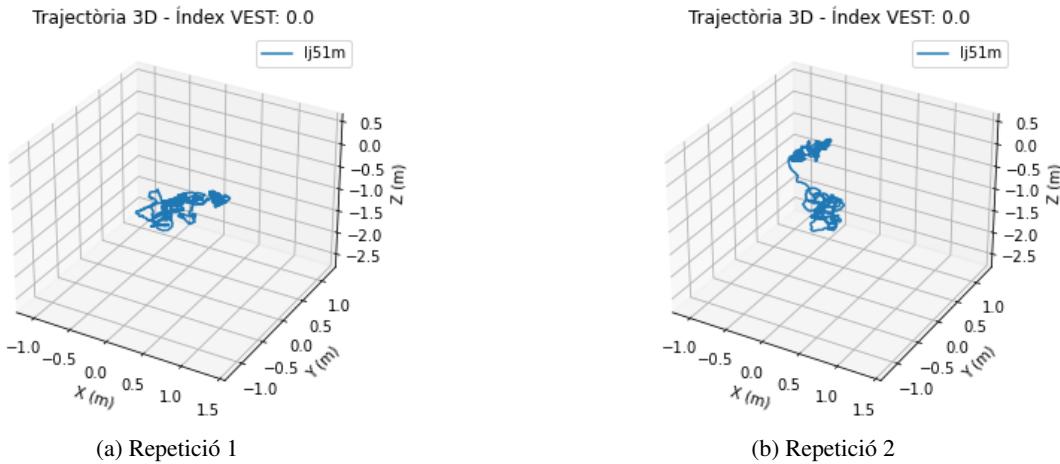


Fig. 95: Trajectòria 3D de tres proves RGA realitzades al mateix pacient amb índex VEST 0.0

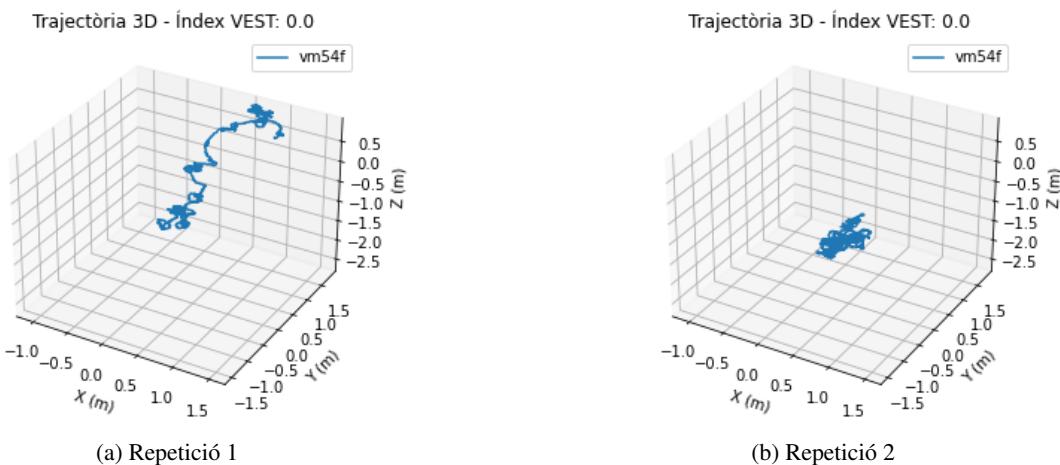


Fig. 96: Trajectòria 3D de dues proves RGA realitzades al mateix pacient amb índex VEST 0.0

B.4.10 Gràfiques prova RGC

B.4.11 Mostres negatives

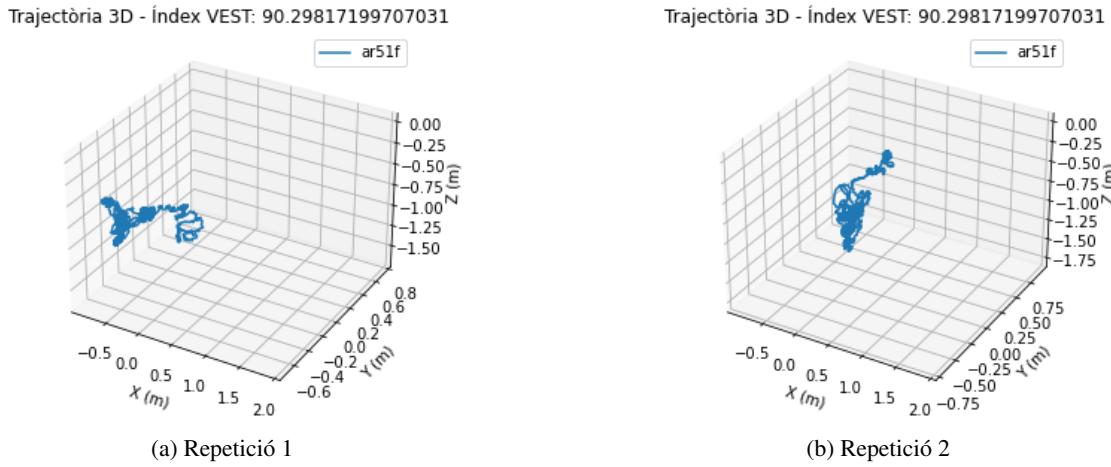


Fig. 97: Trajectòria 3D de dues proves RGC realitzades al mateix pacient amb índex VEST 90.30

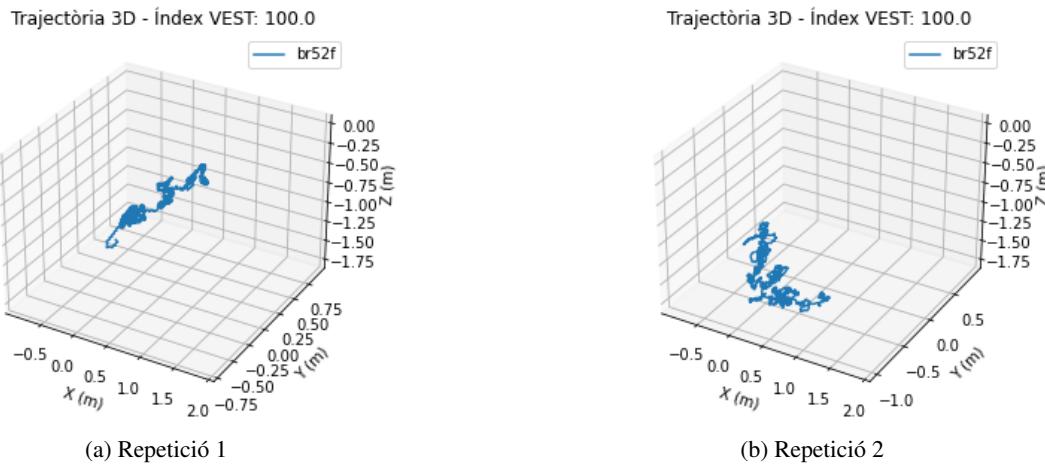


Fig. 98: Trajectòria 3D de dues proves RGC realitzades al mateix pacient amb índex VEST 85.69

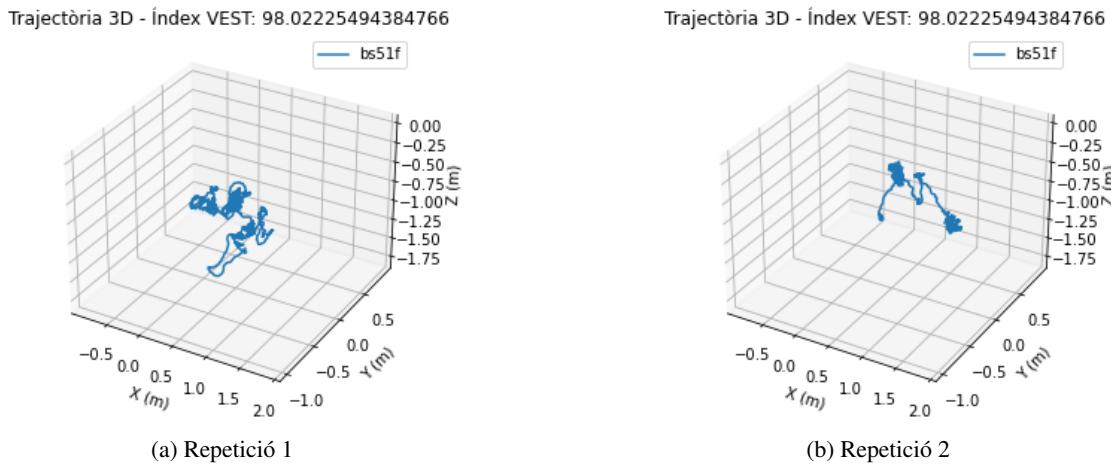


Fig. 99: Trajectòria 3D de dues proves RGC realitzades al mateix pacient amb índex VEST 98.02

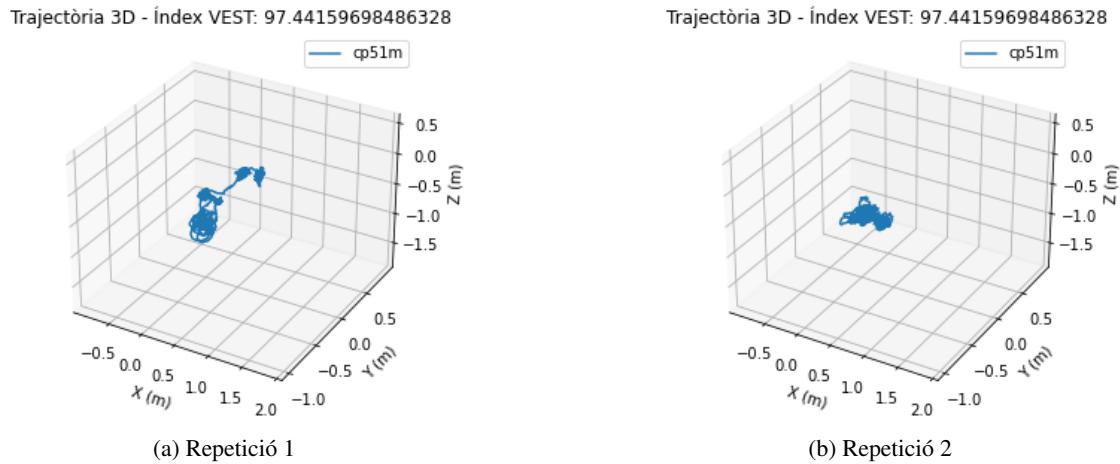


Fig. 100: Trajectòria 3D de tres proves RGC realitzades al mateix pacient amb índex VEST 97.44

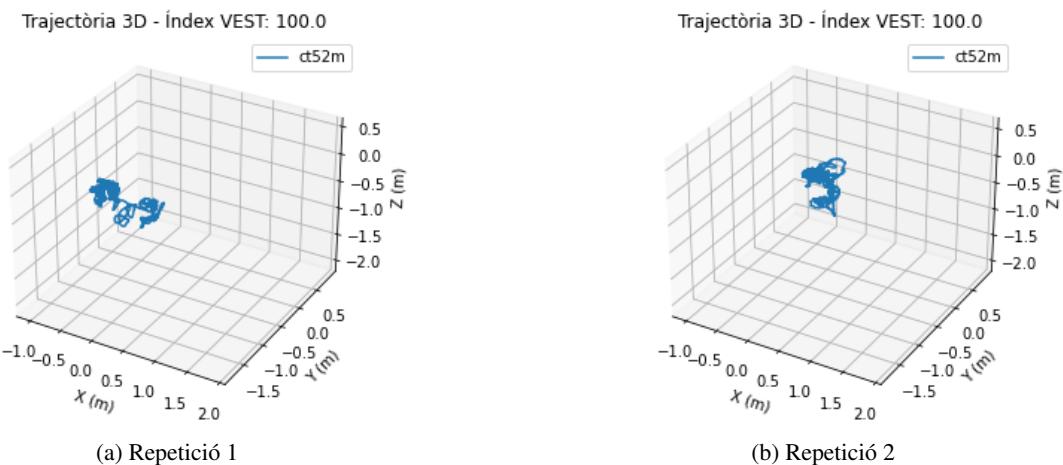


Fig. 101: Trajectòria 3D de dues proves RGC realitzades al mateix pacient amb índex VEST 100

B.4.12 Mostres positives

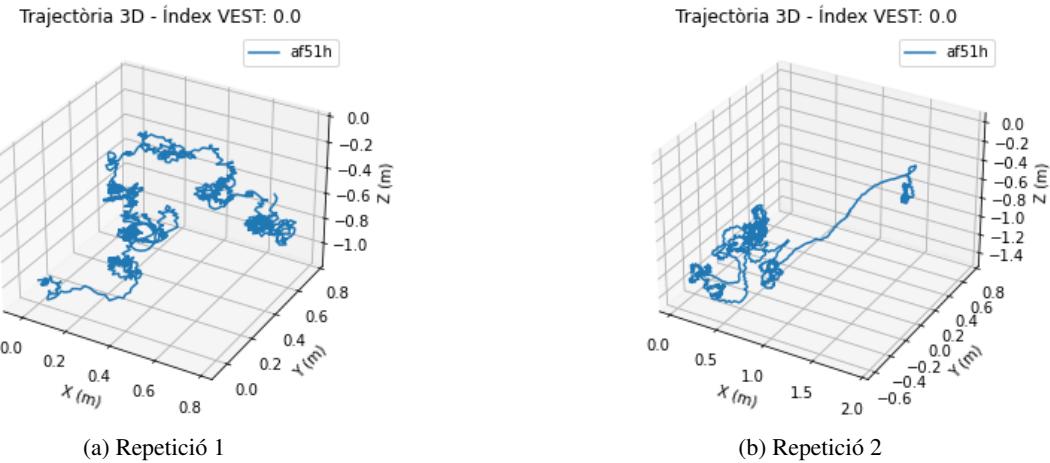


Fig. 102: Trajectòria 3D de tres proves RGC realitzades al mateix pacient amb índex VEST 0.0

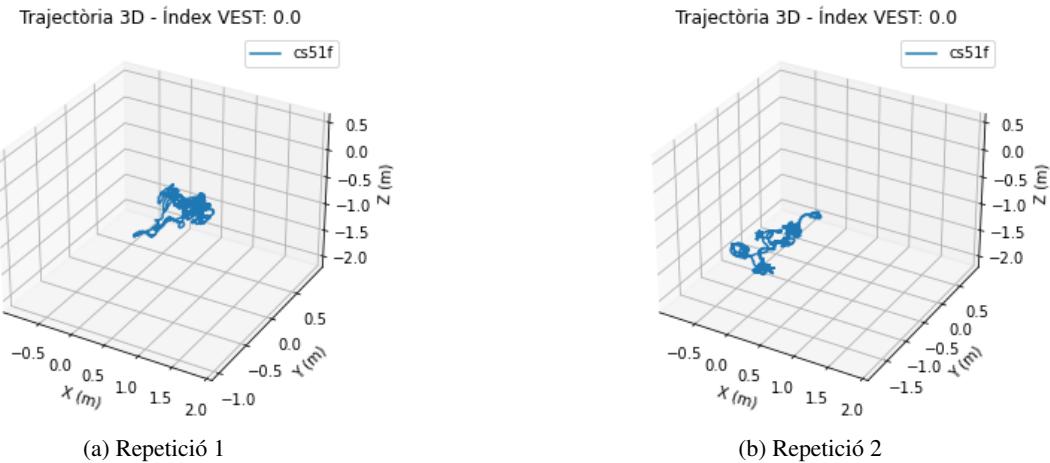


Fig. 103: Trajectòria 3D de tres proves RGC realitzades al mateix pacient amb índex VEST 0.0

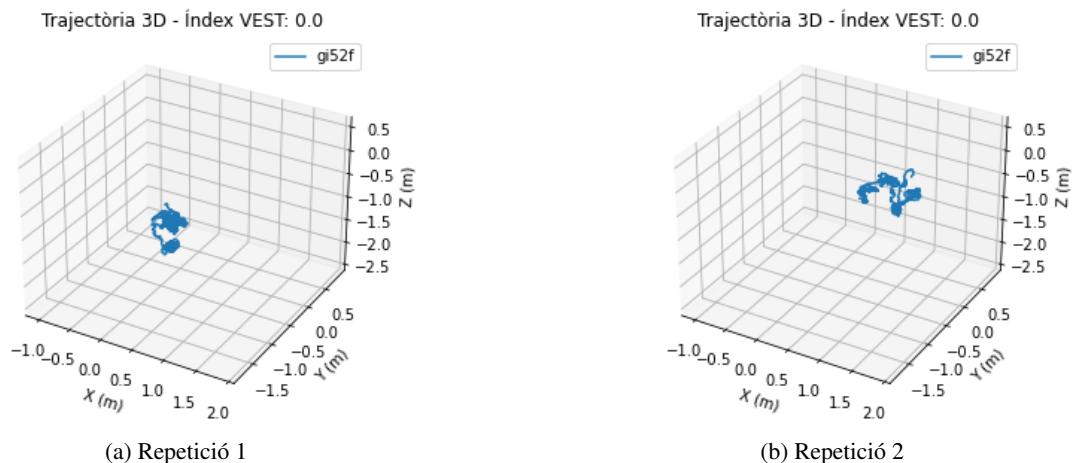


Fig. 104: Trajectòria 3D de dues proves RGC realitzades al mateix pacient amb índex VEST 0.0